Raport 1

Analiza przeżycia

Kacper Haczkiewicz, nr albumu 277515

2026-03-09

Spis treści

1 Lista 1 **2**
1.1 Zadanie 1 2
1.2 Zadanie 2 3
1.3 Zadanie 3 3
1.4 Zadanie 4 4
1.5 Zadanie 5 4

2 Lista 2 **5**
2.1 Zadanie 1 6
2.2 Zadanie 2 7
2.3 Zadanie 3 8

3 Lista 3 **9**
3.1 Zadanie 1 9
3.2 Zadanie 2 11
3.3 Zadanie 3 14

4 Lista 4 **16**
4.1 Zadanie 1 16
4.2 Zadanie 2 18
4.3 Zadanie 3 20

1 Lista 1

1.1 Zadanie 1

W tym zadaniu zadeklaruje wykładniczy rozkład Weibulla, podając jego funkcję gęstości, dystrybuantę, funkcję kwantylową oraz funkcję hazardu.

Niech X będzie zmienną losową z rozkładu Weibulla $\mathcal{EW}(\alpha, \beta, \gamma)$

- Funkcja gęstości: $f(t; \alpha, \beta, \gamma) = \gamma \cdot \frac{\alpha}{\beta} \left(\frac{t}{\beta}\right)^{\alpha-1} e^{-(t/\beta)^\alpha} \left(1 - e^{-(t/\beta)^\alpha}\right)^{\gamma-1} \mathbf{1}_{(0,\infty)}(t)$

```
deweibull <- function(t, a, b, c) {
  if(t>0){
        dew <- c*(a/b)*((t/b)^(a-1))*exp(-1*(t/b)^a)*(1-exp(-1*(t/b)^a))^(c-1)
        return(dew)
  }
    else
        return(0)
}
```

- Dystrybuanta: $F(t; \alpha, \beta, \gamma) = \left(1 - e^{-(t/\beta)^\alpha}\right)^{\gamma} \mathbf{1}_{(0,\infty)}(t)$

```
peweibull <- function(t,a,b,c){
  if(t>0){
        pew <- (1-exp(-1*(t/b)^a))^c
        return(pew)
  }
    else
        return(0)
}
```

- Funkcja kwantylowa: $F^{-1}(t) = \beta \left(-\ln\left(1 - t^{\frac{1}{\gamma}}\right)\right)^{\frac{1}{\alpha}}$

```
qeweibull <- function(t,a,b,c){
  t <- pmin(pmax(t,1e-100), 1 - 1e-100)
  qew<-b*(-log(1-t^(1/c)))^(1/a)
  return(qew)
}
```

- Funkcja hazardu: $\frac{f(t)}{1-F(t)}$

```
heweibull <- function(t,a,b,c){
  h <- (deweibull(t,a,b,c))/(1-peweibull(t,a,b,c))
  return(h)
}
```

1.2 Zadanie 2

Narysujemy cztery wykresy dla różnych parametrów naszego rozkładu $X \sim \mathcal{EW}(\alpha, \beta, \gamma)$

a) $\alpha = \frac{1}{2}, \beta = 2, \gamma = \frac{3}{4}$

b) $\alpha = \frac{3}{2}, \beta = 3, \gamma = 3$

c) $\alpha = \frac{3}{2}, \beta = 4, \gamma = \frac{1}{8}$

d) $\alpha = 1, \beta = 2, \gamma = 1$

e) $\alpha = \frac{3}{4}, \beta = 1, \gamma = 2$

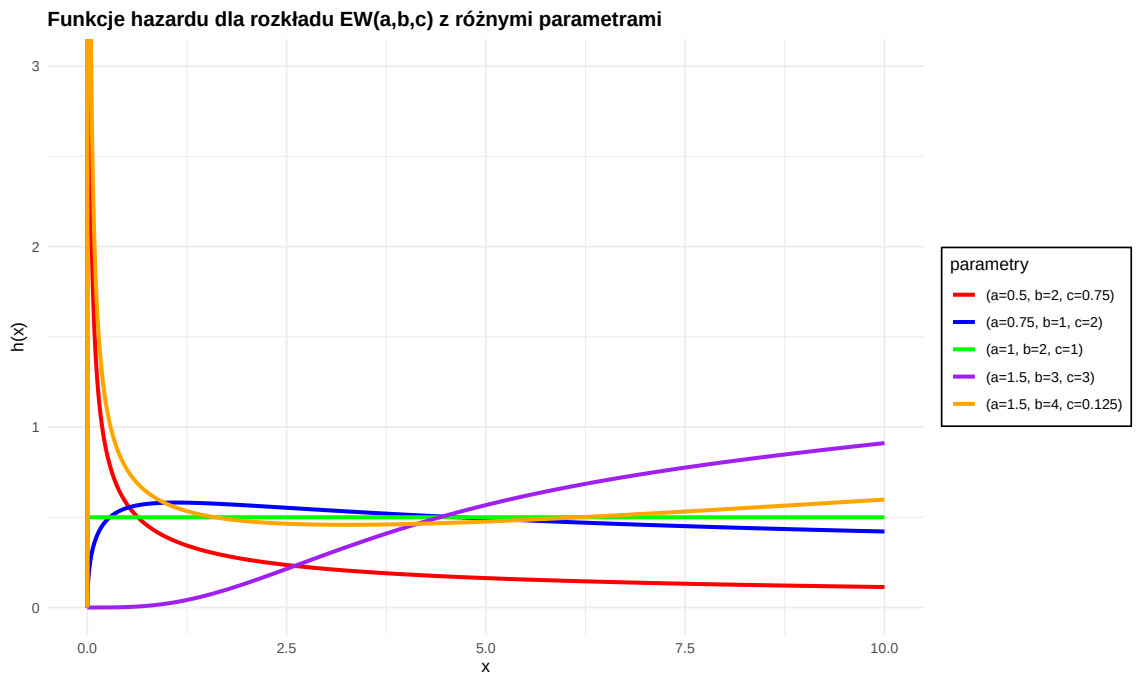

Rysunek 1: Wykresy funkcji hazardu dla EW

Na wykresie (1) widać różne kształty funkcji hazardu dla rozkładów $\mathcal{EW}$ w zależności od parametrów. Dla $\mathcal{EW}(\frac{1}{2}, 2, \frac{3}{4})$ funkcja hazardu jest malejąca. W przypadku $\mathcal{EW}(\frac{3}{4}, 1, 2)$ początkowo lekko rośnie, a następnie stopniowo maleje. Funkcja hazardu dla $\mathcal{EW}(1, 2, 1)$ pozostaje praktycznie stała w całym rozważanym przedziale. Dla $\mathcal{EW}(\frac{3}{2}, 3, 3)$ funkcja rośnie wraz z czasem. Natomiast w przypadku $\mathcal{EW}(\frac{3}{2}, 4, \frac{1}{8})$, przy wartościach t bliskich zeru funkcja hazardu gwałtownie rośnie, po czym zaczyna powoli maleć.

1.3 Zadanie 3

W tym zadaniu stworzę program, który będzie generować zmienne z rozkładu $\mathcal{EW}(\alpha, \beta, \gamma)$.

Algorytm będzie przebiegać tak, że generuję n zmiennych losowych z rozkładu $\mathcal{U}(0, 1)$ $\Big(\mathbb{U}_n = (U_1, \ldots, U_n) \quad iid, U_i \sim \mathcal{U}(0, 1) \quad \forall_{i \in \{1, \ldots, n\}}\Big)$, a następnie stosuję metodę odwrócenia dystrybuanty (funkcji kwantylowej) $X_i = F^{-1}(U_i)$

```r
generator.EW <- function(n, a=1,b=1,c=1){
  u <- runif(n)

  X <- qeweibull(u,a,b,c)
  return(X)
}
```

1.4 Zadanie 4

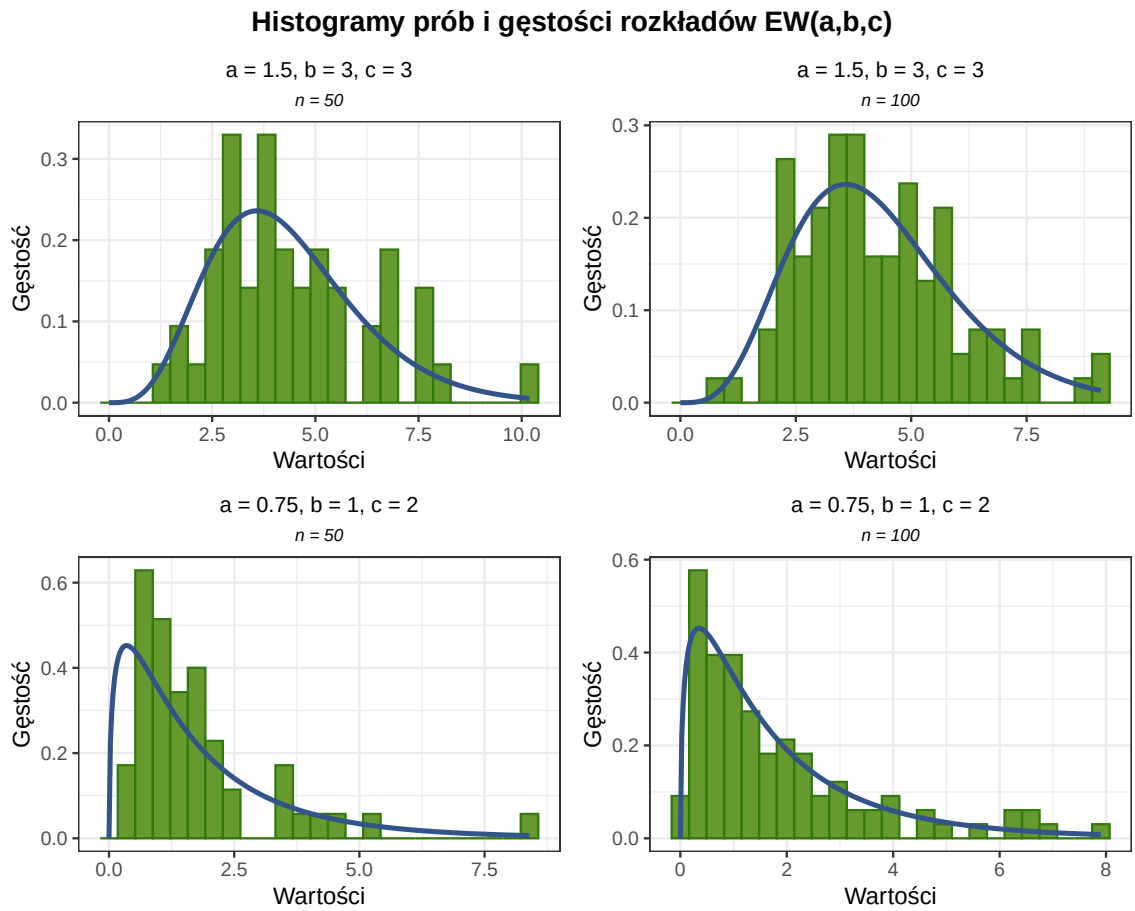

Rysunek 2: Porównanie gęstości teoretycznej z histogramami

Jak można zauważyć na wykresie (2), dla $n = 100$ histogramy w oparciu o dane z rozkładu $\mathcal{EW}\left(\frac{3}{2}, 3, 3\right)$ oraz $\mathcal{EW}\left(\frac{3}{4}, 1, 2\right)$ są bliższe teoretycznej gęstości odpowiadających rozkładów niż dla $n = 50$.

1.5 Zadanie 5

Dla danych z zadania poprzedniego wyznaczę wartości podstawowych statystyk opisowych takich jak:

- Średnia
- Mediana
- Odchylenie standardowe
- Kwantyl dolny oraz górny
- Rostęp
- Minimum i maksimum

W tabeli wyznaczona również jest "teoretyczna" wartość mediany i kwartyli za pomocą własnej funkcji *qeweibul()*:

Do wykonania tabeli 1 wykorzystałem pakiet *KabelExtra*

Tabela 1: Statystyki opisowe dla danych z rozkładu $\mathcal{EW}(\alpha, \beta, \gamma)$

	a=1.5, b=3, c=3		a=0.75,b=1,2	
Statystyka	**n = 50**	**n = 100**	**n = 50**	**n = 100**
Średnia	4.472	4.270	1.752	1.823
Mediana (empiryczne)	4.081	3.941	1.315	1.230
Mediana (teoretyczna)	4.067	4.067	1.315	1.315
Q1 (empiryczny)	3.084	2.954	0.810	0.557
Q1 (teoretyczna)	2.988	2.988	0.613	0.613
Q3 (empiryczny)	5.582	5.308	1.971	2.399
Q3 (teoretyczna)	5.366	5.366	2.537	2.537
Odch. std.	1.895	1.738	1.500	1.758
Minimum	1.472	0.600	0.300	0.036
Maksimum	10.189	9.109	8.397	7.904
Rozstęp	8.716	8.509	8.097	7.868

W tabeli (1) można zauważyć, że empiryczne statystyki: mediana, kwantyl górny i dolny są bardzo zbliżone teoretycznymi statystykami opisowymi. W szczególności, dla $n = 100$ oba rozkłady przybliżają nam je.

2 Lista 2

Niech X będzie zmienną losową o rozkładzie $\mathcal{GE}(\lambda, \alpha), \quad \alpha, \lambda > 0$.

- Funkcja gęstości: $f(x) = \alpha\lambda e^{-\lambda x}\left(1 - e^{-\lambda x}\right)^{\alpha-1}\mathbf{1}_{(0,\infty)}$
- Dystrybuanta: $F_X(t) = \left(1 - e^{-\lambda t}\right)^{\alpha}$

2.1 Zadanie 1

Poniżej znajdują się trzy funkcje, które generują n zmiennych z uogólnionego rozkładu wykładniczego $\mathcal{GE}(\lambda, \alpha)$ dla danych cenzurowanych. Aby stworzyć generator, należy zrobić tak samo, jak to robiliśmy w zadaniu 3 z listy 1, czyli należy dla każdego elementu $u_i, i = 1, \ldots, n$ próbki $u = (u_1, \ldots, u_n)$ wygenerowanej z rozkładu $\mathcal{U}([0, 1])$, utworzyć nowy element x_i za pomocą funkcji kwantylowej:

$$x_i = Q(u_i) = F_X^{-1}(u_i) = -\frac{1}{\lambda} \ln\left(1 - u_i^{\frac{1}{\alpha}}\right)$$

```
qgexp <- function(p, alpha, lambda){
  f.kwantylowa <- -(1/lambda)*log(1 - p^(1/alpha))
  return(f.kwantylowa)
}
```

Najpierw dane cenzurowane I-go typu, które otrzymujemy w wyniku obserwacji n jednostek do chwili t_0, czyli ustalony jest czas obserwacji.

```
generuj.GE.cenzurowane1 <- function(n, alpha, lambda, t0){
  losowe.liczby <- runif(n)
  probka <- sapply(losowe.liczby, FUN = function(u) qgexp(u, alpha, lambda))
  probka <- sort(probka)

  ocenzurowane <- rep(1, length.out = n)
  ocenzurowane[probka > t0] <- 0
  probka[ocenzurowane == 0] <- t0
  df <- data.frame(probka = probka,
                   ocenzurowane = ocenzurowane)

  return(df)
}
```

Teraz dane cenzurowane II-go typu, które otrzymujemy w wyniku prowadzenia eksperymentu do momentu uzyskania m danych kompletnych.

```
generuj.GE.cenzurowane2 <- function(n, alpha, lambda, m){
  losowe.liczby <- runif(n)
  probka <- sapply(losowe.liczby, function(u) qgexp(u, alpha, lambda))

  probka <- sort(probka)

  t.m <- probka[m]

  ocenzurowane <- rep(1, n)
  ocenzurowane[(m+1):n] <- 0
```

```
  probka[(m+1):n] <- t.m

  df <- data.frame(probka = probka,
                   ocenzurowane = ocenzurowane)

  return(df)
}
```

Dane cenzurowane losowo występują w sytuacji, gdy dla każdej obserwowanej i-tej jednostki czas obserwacji kończy się w losowej chwili C_i. Zmienna C_i jest niezależna od rzeczywistego czasu zdarzenia X_i i przyjmuje rozkład o dystrybuancie G oraz gęstości g. Zakłada się, że wszystkie zmienne C_i są niezależne i mają identyczny rozkład, czyli $C_1, C_2, \ldots, C_n \overset{iid}{\sim} G$. Wtedy dla każdej jednostki obserwowany czas ma postać

$$T_i = \min(X_i, C_i)$$

Wskaźnik cenzurowania definiujemy jako

$$\delta_i = \mathbf{1}_{\{X_i \leq C_i\}}.$$

```
generuj.GE.losowo <- function(n, alpha, lambda, eta){
  losowe.liczby <- runif(n)
  X <- sapply(losowe.liczby, function(u) qgexp(u, alpha, lambda))

  C <- rexp(n, rate = 1/eta)

  T <- pmin(X, C)

  delta <- as.numeric(X <= C)

  df <- data.frame(probka = T,
                   ocenzurowane = delta)
  return(df)
}
```

2.2 Zadanie 2

Za pomocą funkcji z poprzedniego zadania, wygeneruje dane z rozkładu $\mathcal{GE}(2, 0.5)$ oraz przedstawie takie statystyki opisowe jak:

- ilość danych kompletnych,
- minimum,
- maksimum,
- mediana,
- kwartyl dolny,

- kwartyl górny,
- rozstęp międzykwartylowy (IQR)

Tabela 2: Statystyki opisowe dla danych cenzurowanych z rozkładu $\mathcal{GE}(2, 0.5)$

Typ cenzurowania	Dane kompletne	Minimum	Maksimum	Mediana	Q1	Q3	IQR
Typ I	13	0.341	1.500	1.500	1.463	1.500	0.037
Typ II	30	0.051	2.764	2.201	1.290	2.764	1.474
Losowe	7	0.005	3.298	0.523	0.276	1.107	0.831

W tabeli (2) możemy zauważyć następujące wnioski:

- Dane cenzurowane typu I-go

Dane są najmniej zróżnicowane (IQR = 0.037), co wynika z faktu, że większość obserwacji osiągnęła ustaloną granicę cenzurowania. Mediana i trzeci kwartyl są równe wartości $t_0 = 1.5$, co świadczy o silnym „ucięciu od góry” i nagromadzeniu obserwacji na poziomie limitu cenzury.

- Dane cenzurowane typu II-go

W tym przypadku uzyskano największą liczbę obserwacji kompletnych (30), a rozstęp międzykwartylowy jest najszerszy (IQR = 1.474). Oznacza to, że dane są najbardziej zróżnicowane — część czasów jest bardzo mała, a część bardzo duża, ponieważ obserwacje kończono dopiero po uzyskaniu ustalonej liczby zakończeń.

- Dane cenzurowane losowo

Dane charakteryzują się umiarkowaną zmiennością (IQR = 0.831) oraz najszerszym zakresem wartości (od 0.005 do 3.298). Liczba obserwacji kompletnych jest najmniejsza (7), co wynika z losowego momentu cenzurowania. Rozkład wartości jest bardziej nieregularny i trudniejszy do przewidzenia niż w pozostałych typach cenzurowania.

2.3 Zadanie 3

W tym zadaniu analizowane dane pochodzą z rocznego badania klinicznego, w którym wzięło udział 40 pacjentów. Zostali oni losowo podzieleni na dwie równe grupy: pierwszej podawano lek A, a drugiej lek B. Dla każdego pacjenta obserwowano czas do remisji choroby, czyli moment, w którym objawy całkowicie ustąpiły.

W grupie otrzymującej lek A u dziesięciu pacjentów remisja nastąpiła w ciągu roku, natomiast u pozostałych dziesięciu nie zaobserwowano poprawy w badanym okresie. Analogiczna sytuacja miała miejsce w grupie przyjmującej lek B — również u połowy pacjentów remisja wystąpiła, a u pozostałych nie.

Oznacza to, że mamy do czynienia z danymi cenzurowanymi prawostronnie, ponieważ dla części pacjentów nie znamy dokładnego czasu wystąpienia remisji, a jedynie wiadomo, że przekroczył on okres jednego roku.

W celu opisu danych obliczone zostały rozsądne statystyki opisowe (minimum, maksimum, medianę, kwartyle oraz rozstęp międzykwartylowy). Pozwalają one scharakteryzować rozkład czasu do remisji w obu grupach i umożliwiają wstępne porównanie skuteczności badanych leków.

Otrzymane wyniki przedstawione są w tabeli 3.

Tabela 3: Statystyki opisowe dla remisji w grupach A i B

Grupa	Minimum	Maksimum	Mediana	Q1	Q3	IQR
A	0.033	0.942	0.343	0.127	0.628	0.501
B	0.038	0.691	0.324	0.214	0.441	0.227

Wyniki sugerują, że grupa A ma większe zróżnicowanie poziomu remisji — niektórzy pacjenci osiągają bardzo dobre wyniki, ale też zdarzają się gorsze. Natomiast grupa B ma bardziej jednorodne wyniki, lecz ogólnie niższy potencjał maksymalny remisji. Można więc przypuszczać, że leczenie w grupie A jest bardziej „ryzykowne”, ale potencjalnie skuteczniejsze dla niektórych pacjentów.

3 Lista 3

3.1 Zadanie 1

Na podstawie zadania 3 z listy 2, wyznaczę oszacowania największej wiarogodności średniego czasu do remisji choroby dla pacjentów leczonych lekiem A oraz pacjentów leczonych lekiem B. Przyjmujemy, że dane są realizacjami rozkładu wykładniczego $\mathcal{E}(\vartheta)$.

Są to dane prawostronnie cenzurowane I-go typu, zatem funkcja wiarogodności jest postaci:

$$L(\vartheta; \mathbf{t}^*) = \frac{n!}{(n-r)!} \prod_{i=1}^{r} f_\vartheta(x_{(i)}) \left[1 - F_\vartheta(t_0)\right]^{n-r}, \tag{1}$$

gdy $0 < x_{(1)} < x_{(2)} < \cdots < x_{(n)} < \infty$, gdzie f_ϑ oznacza gęstość rozkładu zmiennych $X_1, \ldots, X_n$, F_ϑ - dystrybuantę tego rozkładu, r jest realizacją zmiennej losowej R - losowej liczby obserwacji niecenzurowanych (kompletnych) w przedziale $(0, t_0]$, t_0 oznacza czas cenzurowania, n - całkowita liczba obserwacji.

Wtedy oszacowanie NW nieznanego parametru ϑ polega na znalezieniu takiej wartości $\hat{\vartheta}$, dla której

$$L(\hat{\vartheta}; \mathbf{t}^*) = \sup_{\vartheta \in \Theta} L(\vartheta; \mathbf{t}^*),$$

gdzie $L(\vartheta; \mathbf{t}^*)$ określona jest wzorem (1)

Z wykładu również wiemy, że dla rozkładu wyjkładniczego $\mathcal{E}(\vartheta)$ funkcja wiarogodności jest postaci:

$$L(\vartheta; \mathbf{t}^*) = \frac{n!}{(n-r)!}\vartheta^r \exp\{-\vartheta[\sum_{i=1}^{r} x_{(i)} + t_0(n-r)]\} \tag{2}$$

Dla naszego zadania będziemy korzystać z funkcji (2)

```
remisja.A <- c(0.03345514, 0.08656403, 0.08799947, 0.24385821, 0.27755032,
               0.40787247, 0.58825664, 0.64125620, 0.90679161, 0.94222208)
remisja.B <- c(0.03788958, 0.12207257, 0.20319983, 0.24474299, 0.30492413,
               0.34224462, 0.42950144, 0.44484582, 0.63805066, 0.6911972)

n<-20
r<-10
t0<-1

funkcja.nw.exp <- function(theta, xi, n, r, t0){
  L.exp <- (factorial(n)/factorial(n-r))*theta^r *
    exp(-theta*(sum(xi) + t0*(n-r)))
  return(L.exp)
}

# lek A
optymalizacja.nw.A <- optimize(function(theta)
                               funkcja.nw.exp(theta, remisja.A, n, r, t0),
                               interval = c(0.001, 10), maximum = TRUE)

max.nw.A <- optymalizacja.nw.A$maximum

est.nw.A <- 1 / max.nw.A

# lek B
optymalizacja.nw.B <- optimize(function(theta)
                               funkcja.nw.exp(theta, remisja.B, n, r, t0),
                               interval = c(0.001, 10), maximum = TRUE)

max.nw.B <- optymalizacja.nw.B$maximum

est.nw.B <- 1/max.nw.B
```

Dla danych cenzurowanych I-go typu mamy następujące oszacowania:

- Dla leku A: 1.422,
- Dla leku B: 1.346.

Można więc stwierdzić, że remisja choroby nastąpi szybciej dla grupy pacjentów otrzymujących lek B.

Teraz dokonam realizację przedziału ufności na poziomie ufności $1-\alpha$, dla średniego czasu do remisji choroby dla pacjentów leczonych lekiem A oraz pacjentów leczonych lekiem B. Przyjmuję $\alpha = 0.05$ oraz $\alpha = 0.01$.

Wiedząc z wykładu, że $R = \sum_{i=1}^{n} \mathbf{1}(X_i \leq t_0)$ ma rozkład *dwumianowy* $\mathcal{B}(n, F_\vartheta(t_0))$, dysponując przedziałem ufności $[T_L, T_U]$, na poziomie istotności $1-\alpha$, dla prawdopodobieństwa sukcesu

$$p = F_\vartheta(t_0) = 1 - e^{-\vartheta t_0}$$

, po odpowiednich przekształceniach, można uzyskać przedział ufności $[\tilde{T_L}, \tilde{T_U}]$ na poziomie istosności $1-\alpha$, dla parametru ϑ gdzie:

$$\tilde{T_L} = -\frac{\ln(1-T_L)}{t_0}, \quad \tilde{T_U} = -\frac{\ln(1-T_U)}{t_0}$$

```r
przedzial_ufnosci_cenz_I <- function(r,n,t0, alpha){
  T <- binom.confint(r,n, conf.level = 1-alpha, methods = "bayes")

  T.L <- -log(1-T$lower)/t0
  T.U <- -log(1-T$upper)/t0

  przedzial = c(T.L, T.U)
  return(przedzial)
}

przedzial_A_95 <- przedzial_ufnosci_cenz_I(r, n, t0, 0.05)
przedzial_A_99 <- przedzial_ufnosci_cenz_I(r, n, t0, 0.01)

przedzial_B_95 <- przedzial_ufnosci_cenz_I(r, n, t0, 0.05)
przedzial_B_99 <- przedzial_ufnosci_cenz_I(r, n, t0, 0.01)
```

Tabela 4: Realizacja przedziałów ufności dla średniego czasu do remisji choroby

Pacjenci leczeni lekiem	Poziom 0.95	Poziom 0.99
A	(0.347; 1.226)	(0.271; 1.439)
B	(0.347; 1.226)	(0.271; 1.439)

Realizacja przedziałów ufności na danych poziomach ufności umieszczone są w tabeli (4). Jak można zauważyć, przedziału dla różnego poziomu istotności są takie same zarówno dla leku A, jak i B. Wynika to z tego, że parametry n, r, t_0 są takie same dla obu leków.

3.2 Zadanie 2

Z zadania 1 wiadomo, że obserwacje czasu do remisji choroby były prowadzone do momentu, w którym u dziesięciu pacjentów zostanie ona zaobserwowana, wyznaczyć oszacowania z punktu (a) i (b) zadania 1. Są to zatem dane cenzurowane II-go typu.

Dla rozkładu wykładniczego $\mathcal{E}(\vartheta)$ funkcja wiarogodności dla danych cenzurowanych II-go typu jest postaci:

$$L(\vartheta; \mathbf{t}^*) = \frac{n!}{(n-m)!}\vartheta^m \exp\{-\vartheta[\sum_{i=1}^{r} x_{(i)} + (n-m)x_{(m)}]\} \tag{3}$$

Dla naszego zadania będziemy korzystać z funkcji (3)

```
remisja.A <- c(0.03345514, 0.08656403, 0.08799947, 0.24385821, 0.27755032,
               0.40787247, 0.58825664, 0.64125620, 0.90679161, 0.94222208)
remisja.B <- c(0.03788958, 0.12207257, 0.20319983, 0.24474299, 0.30492413,
               0.34224462, 0.42950144, 0.44484582, 0.63805066, 0.6911972)

n <-20
m <-10

funkcja.nw.exp2 <- function(theta, xi, n, m){
  x.m <- max(xi)
  L.exp <- (factorial(n)/factorial(n-m))*theta^r *
    exp(-theta*(sum(xi) + (n-m)*x.m))
  return(L.exp)
}

# lek A
optymalizacja.nw.A2 <- optimize(function(theta)
                                funkcja.nw.exp2(theta, remisja.A, n, m),
                                interval = c(0.001, 10), maximum = TRUE)

max.nw.A2 <- optymalizacja.nw.A2$maximum

est.nw.A2 <- 1 / max.nw.A2

# lek B
optymalizacja.nw.B2 <- optimize(function(theta)
                                funkcja.nw.exp2(theta, remisja.B, n, m),
                                interval = c(0.001, 10), maximum = TRUE)

max.nw.B2 <- optymalizacja.nw.B2$maximum

est.nw.B2 <- 1/max.nw.B2
```

Dla danych cenzurowanych II-go typu mamy następujące oszacowania:

- Dla leku A: 1.364,
- Dla leku B: 1.037.

Podobnie jak w poprzednim zadaniu z tej listy (1a), również oczekujemy, że remisja choroby nastąpi szybciej dla grupy pacjentów otrzymujących lek B.

Przedział ufności dla danych cenzurowanych II-go typu konstruujemy z faktu z wykładu, czyli jeżeli zmienne losowe $X_i, \quad i = 1, \ldots, n$ mają rozkład *wykładniczy* $\mathcal{E}(\vartheta)$, to ϑX_i mają rozkład *wykładniczy* $\mathcal{E}(1)$.

Wtedy zmienna losowa

$$\frac{\vartheta \sum_{i=1}^{m} D_i}{m} = \frac{\sum_{i=1}^{n} D_i}{m\mu}$$

, gdzie $D_i = (n - i + 1)(X_{(i)} - X_{(i-1)})$ są tzw. *unormowanymi spacjami*, ma rozkład *gamma* $\mathcal{G}(m, \frac{1}{m})$. Wtedy dla każdego $\vartheta > 0$ i $\alpha_1 + \alpha_2 = \alpha$ mamy, że

$$\mathbb{P}_\vartheta \left(q_m(\alpha_1) \leq \frac{\vartheta \sum_{i=1}^{m} D_i}{m} \leq q_m(1 - \alpha_2) \right) = 1 - \alpha$$

, gdzie $q_m(p)$ jest kwantylem rzędu p rozkładu $\mathcal{G}(m, \frac{1}{m})$.

Z powyższego, przedział ufności $[T_L, T_U]$, gdzie:

$$T_L = \frac{m q_m(\alpha_1)}{\sum_{i=1}^{m} D_i}, \quad T_U = \frac{m q_m(1 - \alpha_2)}{\sum_{i=1}^{m} D_i}$$

jest przedziałem ufności dla parametru ϑ rozkładu *wykładniczego*, na poziomie istotności $1 - \alpha$.

Na potrzeby zadania, przyjmijmy, że $\alpha_1 = \alpha_2 = \frac{\alpha}{2}$.

Poniższa funkcja realizuje przedział ufności na poziomie istotności $1 - \alpha$ stosując się do powyższej teorii.

```
przedzial_ufnosci_cenz_II<- function(X, n,m, alpha){
  X.sort <- sort(X)
  D <- numeric(m)
  X.sort <- c(0, X.sort) # wykład 3, uwzględniam X_0 = 0
  for(i in 1:m){
    D[i] <- (n - i + 1) * (X.sort[i+1] - X.sort[i])
  }

  suma_D <- sum(D)

  alpha1 <- alpha / 2
  alpha2 <- alpha / 2
  q_lower <- qgamma(alpha1, shape = m, rate = m)
  q_upper <- qgamma(1 - alpha2, shape = m, rate = m)

  TL <- (m * q_lower) / suma_D
  TU <- (m * q_upper) / suma_D
```

```
  przedzial <- c(TL,TU)
  return(przedzial)
}
```

Tabela 5: Realizacja przedziałów ufności dla średniego czasu do remisji choroby dla danych cenzurowanych II-go typu

Pacjenci leczeni lekiem	Poziom 0.95	Poziom 0.99
A	[0.352; 1.253]	[0.273; 1.466]
B	[0.462; 1.647]	[0.358; 1.928]

W tabeli 5 przedstawiono realizację przedziałów ufności dla średniego czasu do remisji choroby w grupach pacjentów leczonych lekami A i B, przy danych cenzurowanych II-go typu. Jak można zauważyć, przedziały ufności różnią się między grupami oraz zależnie od przyjętego poziomu ufności (0.95 i 0.99). Dla grupy A średni czas remisji mieści się w przedziale od 0.352 do 1.253 przy poziomie ufności 0.95, natomiast przy poziomie 0.99 przedział rozszerza się do (0.273; 1.466). Analogicznie, dla grupy B przedziały są szersze: $[0.462; 1.647]$ dla poziomu 0.95 oraz $[0.358; 1.928]$ dla poziomu 0.99. Wynika z tego, że przy wyższym poziomie ufności przedziały stają się szersze, co jest zgodne z intuicją statystyczną.

3.3 Zadanie 3

Niech $X_1, \ldots, X_n$ będą zmiennymi losowymi *iid*, $X1 \sim \mathcal{E}(\vartheta)$:

$$f_\vartheta(x) = \vartheta e^{-\vartheta x} \mathbf{1}_{(0,\infty)}(x) \tag{4}$$

Niech t_0 będzie ustalonym czasem obserwacji. Wówczas, na podstawie danych cenzurowanych I-go typu, możemy szacować nieznaną wartość parametru ϑ przy użyciu następujących estymatorów:

$$\hat{\vartheta} = \frac{R}{T_1}, \tag{5}$$

gdzie $R = \sum_{i=1}^{n} \mathbf{1}(X_i \leq t_0), \quad T_1 = \sum_{i=1}^{R} X_{(i)} t_0 (n - R)$

oraz

$$\tilde{\vartheta} = -\frac{\log(1 - \frac{R}{n})}{t_0} \tag{6}$$

Na podstawie estymatorów (5) oraz (6) przeprowadzę symulację w celu porównania estymatorów. Wynikiem będzie tabela z oszacowaniami obciążeń (*Bias*), jak również błąd średniokwadratowy (*MSE*), dla wartości $\vartheta = 1, \quad n = 10, 30, \quad t_0 = 0.5, 1, 2.$

Przypomnę, że błąd oszacowania wyrażony jest wzorem $Bias(\check{\vartheta}, \vartheta) = \mathbb{E}_\vartheta(\check{\vartheta} - \vartheta)$ oraz błąd średniokwadratowy: $MSE(\check{\vartheta}, \vartheta) = \mathbb{E}_\vartheta(\check{\vartheta} - \vartheta)^2$, gdzie $\check{\vartheta}$ jest estymatorem parametru ϑ.

Funkcja przedstawiona poniżej została zastosowana do przeprowadzenia symulacji dla 1000000 replikacji.

```r
symulacja <- function(theta, n, t0, M = 1000000){

  # miejsce na wyniki
  est_hat <- numeric(M)
  est_tilde <- numeric(M)

  # liczba przypadków pełnej obserwacji (R = n)
  full_obs_count <- 0

  for(i in seq_len(M)){
    x <- rexp(n, theta)
    R <- sum(x <= t0)
    x_obs <- x[x <= t0]
    T1 <- sum(x_obs) + t0 * (n - R)
    est_hat[i] <- R / T1

    if(R == n){
      # pełna informacja { stosujemy estymator średniej
      est_tilde[i] <- mean(x)
      full_obs_count <- full_obs_count + 1
    } else {
      est_tilde[i] <- -log(1 - R/n) / t0
    }
  }

  # obciążenia i MSE
  bias_hat <- mean(est_hat) - theta
  bias_tilde <- mean(est_tilde) - theta

  mse_hat <- mean((est_hat - theta)^2)
  mse_tilde <- mean((est_tilde - theta)^2)

  # zwrot danych
  data.frame(
    bias.hat = bias_hat,
    bias.tilde = bias_tilde,
    mse.hat = mse_hat,
    mse.tilde = mse_tilde,
    liczba.R.eq.n = full_obs_count
  )
}
```

Tabela 6: Wyniki symulacji porównujących estymatory $\hat{\vartheta}$ oraz $\tilde{\vartheta}$ dla rozkładu wykładniczego z cenzurowaniem I-go typu.

n	t_0	$Bias(\hat{\theta})$	$MSE(\hat{\theta})$	$Bias(\tilde{\theta})$	$MSE(\tilde{\theta})$	Zamiana $\tilde{\theta}$ **na średnią**
10	0.5	0.0642	0.3110	0.0746	0.3371	84
10	1.0	0.0741	0.2105	0.0778	0.2251	10240
10	2.0	0.0917	0.1760	-0.1307	0.0759	233796
30	0.5	0.0202	0.0902	0.0227	0.0934	0
30	1.0	0.0231	0.0576	0.0313	0.0668	1
30	2.0	0.0274	0.0437	0.0468	0.0688	12792

Dla sytuacji, gdy dane są kompletne (dla $R = n$), estymator $\tilde{\vartheta}$ nie jest dobrze zdefiniowany. Dla prób, w których tak było, estymator ten zastąpiony jest średnią z próby. W tabeli {**??**} wyświetlona jest ilość zamiany estymatora $var\tilde{t}heta$ na średnią.

Jak widać, dla $n = 30$ wartości błędy oszacowań oraz błędy średniokwadratowe dla obu estymatorów oraz t_0 są bliższe zeru, niż dla $n = 10$. Można więc wywnioskować, że gdy n jest większe, tym większa jest dokładność estymacji parametru ϑ.

4 Lista 4

4.1 Zadanie 1

Załóżmy, że mamy próbę z rozkładu *wykładniczego* $\mathcal{E}(\vartheta)$, $\quad \vartheta > 0$ dla danych cenzurowanych I-go typu prawostronnie. W próbie jest n obserwacji, z czego r to obserwacje kompletne. Oznaczamy

$$S = \sum_{i=1}^{r} x_{(i)} + t_0(n - r).$$

Funkcja wiarogodności (z dokładnością do stałej) ma postać

$$L(\vartheta; r, S) \propto \vartheta^r e^{-\vartheta S}.$$

Estymator największej wiarogodności to

$$\hat{\vartheta} = \frac{r}{S}.$$

Statystyka ilorazu wiarogodności ma postać

$$\lambda(r, S) = \frac{\sup_{\vartheta \in \Theta_0} L(\vartheta; r, S)}{L(\hat{\vartheta}; r, S)}.$$

Statystykę testową definiujemy jako

$$T = -2 \log \lambda(r, S).$$

Dla dużych prób, na mocy twierdzenia Wilksa,

$$T \overset{d}{\approx} \chi^2_1.$$

W związku z tym p-wartość testu przybliżamy przez

$$p = 1 - F_{\chi^2_1}(T).$$

Rozważane hipotezy na poziomie istotności α:

1. Hipoteza dwustronna

$$H_0 : \vartheta = \vartheta_0, \qquad H_1 : \vartheta \neq \vartheta_0,$$

   dla której

$$\sup_{\vartheta \in \Theta_0} L = L(\vartheta_0).$$

2. Hipoteza prawostronna

$$H_0 : \vartheta \leq \vartheta_0, \qquad H_1 : \vartheta > \vartheta_0,$$

   gdzie

$$\sup_{\vartheta \in \Theta_0} L(\vartheta) = \begin{cases} L(\hat{\vartheta}), & \text{gdy } \hat{\vartheta} \leq \vartheta_0, \\ L(\vartheta_0), & \text{gdy } \hat{\vartheta} > \vartheta_0. \end{cases}$$

3. Hipoteza lewostronna

$$H_0 : \vartheta \geq \vartheta_0, \qquad H_1 : \vartheta < \vartheta_0,$$

   gdzie

$$\sup_{\vartheta \in \Theta_0} L(\vartheta) = \begin{cases} L(\hat{\vartheta}), & \text{gdy } \hat{\vartheta} \geq \vartheta_0, \\ L(\vartheta_0), & \text{gdy } \hat{\vartheta} < \vartheta_0. \end{cases}$$

Poniżej znajduje się kod funkcji, której wartością dla danych tego typu, będzie wartość poziomu krytycznego (*p-value*) w teście ilorazu wiarogodności do testowania powyższych hipotez.

```
p.value <- function(r, s, n, t0, theta0, typ){
  if (r == 0) {
    # wszystkie obserwacje cenzurowane
    return(1)  # nie mamy podstaw do odrzucenia H0
  }
  # estymator NW
  theta.hat <- r / s

  # logarytmiczny iloraz wiarogodności
```

```
  logL.h0  <- r * log(theta0) - theta0 * s
  logL.hat <- r * log(theta.hat) - theta.hat * s

  # statystyka testowa
  T <- -2 * (logL.h0 - logL.hat)

  # wybór p-value w zależności od typu hipotezy
  if (typ == 1) {
    # H0: theta = theta0, H1: theta != theta0
    p <- 1 - pchisq(T, df = 1)

  } else if (typ == 2) {
    # H0: theta <= theta0, H1: theta > theta0
    if (theta.hat > theta0) {
      p <- 1 - pchisq(T, df = 1)
    } else {
      p <- 1
    }

  } else if (typ == 3) {
    # H0: theta >= theta0, H1: theta < theta0
    if (theta.hat < theta0) {
      p <- 1 - pchisq(T, df = 1)
    } else {
      p <- 1
    }

  }
  return(p)
}
```

4.2 Zadanie 2

Aby ocenić działanie testu ilorazu wiarogodności z zadania 1 (a), przeprowadzę symulację rozmiaru testu oraz jego mocy dla wybranej wartości ϑ_0, t_0 oraz $n \in \{20, 50\}$ Wybrane alternatywy to $\vartheta_0 \in \{0.2, 0.4, 0.6, \ldots, 1.8, 2\}$. Przyjmuję poziom istotności $\alpha = 0.05$

```
symulacja2 <- function(theta0=1, t0=1, n, M=1000000, alpha=0.05){
  alternatywy <- seq(0.2, 2.0, length.out = 10)
  results <- numeric(length(alternatywy))

  for (i in seq_along(alternatywy)) {

    theta <- alternatywy[i]
```

```r
    odrz <- 0

    for (b in 1:M) {

      x <- rexp(n, rate = theta)

      delta <- x <= t0
      r <- sum(delta)
      s <- sum(x[delta]) + t0 * (n - r)

      pval <- p.value(r, s, n, t0, theta0, typ = 1)

      if (pval < alpha) {
        odrz <- odrz + 1
      }
    }

    results[i] <- odrz / M
  }

  return(data.frame(
    theta = alternatywy,
    wynik = results
  ))
}
```

Na wykresie (3) przedstawiona została symulacja 1000000 replikacji mocy testów dla różnych wartości parametru ϑ oraz dla $n \in \{20, 50\}$

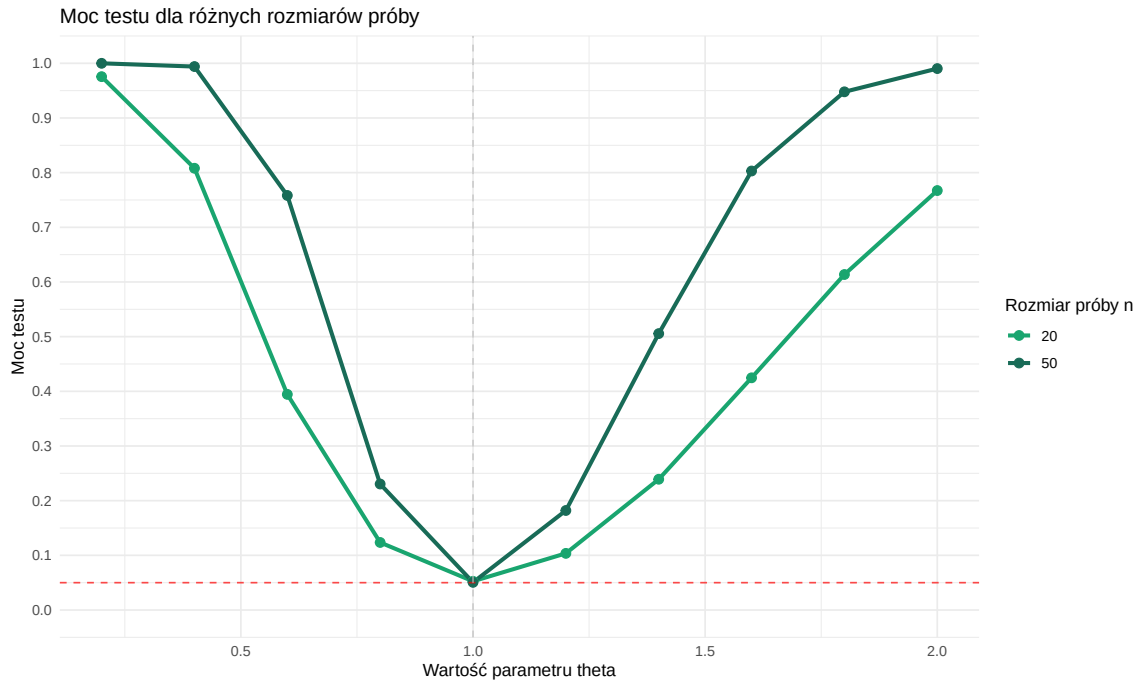

Rysunek 3: Symulowane moce testów dla różnych wartości parametru theta oraz n

Na wykresie (3) przedstawiono symulowane funkcje mocy testu ilorazu wiarogodności dla weryfikacji hipotezy $H_0 : \theta = 1$ przeciwko $H_1 : \theta \neq 1$ na poziomie istotności $\alpha = 0.05$. Można zauważyć, że dla $n = 20$ funkcja mocy testu spada łagodniej zbliżając się do ϑ_0, co wskazuje na mniejszą moc testu. Wnioskując, gdy wartości naszej funkcji mocy są większe od ϑ_0, prawdopodobieństwo odrzucenia H_0 się zwiększa.

Dla $n = 50$ krzywa mocy jest bardziej stroma i osiąga wyższe wartości przy tych samych alternatywach. Sugeruje to, że dla większej próby dokładność testu jest większa.

4.3 Zadanie 3

Dla danych z zadania 3 z listy 2, przyjmując, że są one realizacjami zmiennych z rozkładu wykładniczego $\mathcal{E}(\vartheta)$, obliczono wartość poziomu krytycznego za pomocą funkcji z zadania 1 z listy 4. Przyjmujemy poziom istotności $\alpha = 0.05$

```
t0 <- 1
theta0 <- 1

# Remisja dla leku A
remisja.A <- c(0.03345514, 0.08656403, 0.08799947, 0.24385821, 0.27755032,
               0.40787247, 0.58825664, 0.64125620, 0.90679161, 0.94222208)
n.A <- 20
r.A <- 10
s.A <- sum(remisja.A) + t0 * (n.A-r.A) # kompletne + cenzurowane
```

```r
p.A <- p.value(r.A, s.A, n.A, t0, theta0, 1)

# Remisja dla leku B
remisja.B <- c(0.03788958, 0.12207257, 0.20319983, 0.24474299, 0.30492413,
               0.34224462, 0.42950144, 0.44484582, 0.63805066, 0.6911972)
n.B <- 20
r.B <- 10
s.B <- sum(remisja.B) + t0 * (n.B-r.B)
t0 <- 1

p.B <- p.value(r.B, s.B, 20, t0, theta0, 1)
```

Poziom krytyczny dla leku A wynosi około 0.237, dla leku B około 0.323. Obie wartości są większe niż poziom istotności. Zatem nie mamy podstaw do odrzucenia hipotez, że średni czas do remisji choroby w grupie A oraz w grupie B wynosi 1.