Raport 2

Analiza przeżycia

Kacper Haczkiewicz, nr albumu 277515

2025-12-08

Spis treści

1 Lista 5 **2**
1.1 Zadanie 1 2
1.2 Zadanie 2 4
1.3 Zadanie 3 5

2 Lista 6 **8**
2.1 Zadanie 1 8
2.2 Zadanie 2 10

3 Lista 7 **11**
3.1 Zadanie 1 11
3.2 Zadanie 2 12

4 Lista 8 **13**
4.1 Zadanie 1 13
4.2 Zadanie 2 14

1 Lista 5

Niech $X_1, \ldots, X_n$ będą niezależnymi zmiennymi losowymi o jednakowym rozkładzie o nie- znanej dystrybuancie F. Niech z każdą zmienną X_i związana będzie zmienna losowa cenzu- rująca Ci. Załóżmy ponadto, że dla każdego $i = 1, \ldots, n$, zmienna losowa X_i jest niezależna od zmiennej losowej C_i.

1.1 Zadanie 1

Celem tego zadania jest stworzenie wykresów estymatorów Kaplana-Meiera oraz Fleminga-Harringtona funkcji przeżycia czasu do remisji choroby pacjentów leczonych lekiem A oraz lekiem B (dane pochodzą z zadania 3 z listy 2). Rozważmy problem estymacji funkcji przeżycia na podstawie obserwacji zmiennych losowych

$$T_i = \min(X_i, C_i)$$

oraz

$$\delta_i = \mathbf{1}_{\{X_i \leq C_i\}}, \quad i = 1, \ldots, n$$

1) Estymator Kaplana–Meiera

Estymator Kaplana-Meiera ma postać

$$\widehat{S}(t) = \prod_{i:t_{(i)} \leq t} \frac{r_i - d_i}{r_i}, \tag{1}$$

gdzie r_i oznacza liczbę osób będących w stanie ryzyka w punkcie $t_{(i)}$, d_i - liczba zdarzeń, które zaszły w chwili $t_{(i)}$. Na poniższym rysunku (1) przedstawiony jest estymator Kaplana-Meiera dla funkcji przeżycia.

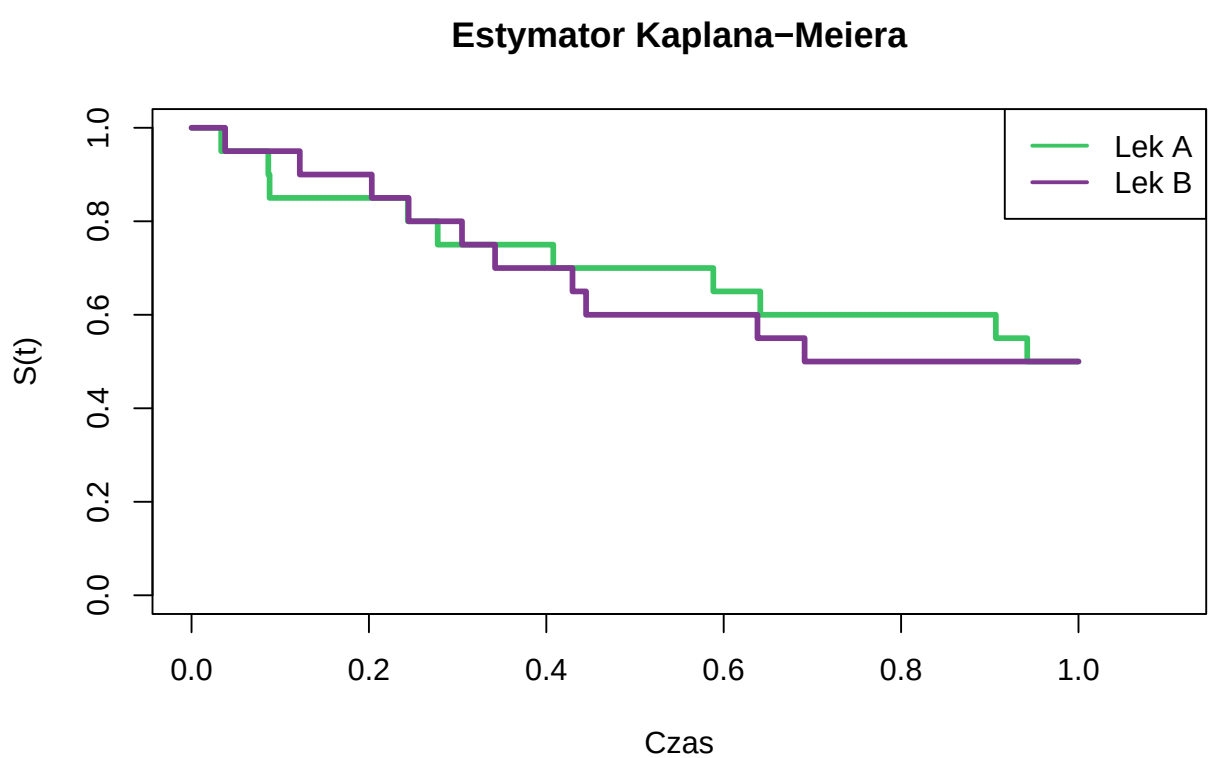

Rysunek 1: Wykres estymatora Kaplana-Meiera funkcji przeżycia

Krzywe Kaplana–Meiera dla leków A i B mają bardzo zbliżony przebieg. Lek B wykazuje nieco szybszy spadek funkcji przeżycia, natomiast w dalszym okresie wartości dla obu leków są zbliżone. Na podstawie tych wyników nie obserwuje się wyraźnych różnic w skuteczności działania leków.

2) Estymator Fleminga-Harringtona

Estymator Fleminga–Harringtona jest alternatywnym estymatorem funkcji przeżycia, wykorzystującym zależność

$$S(t) = \exp[-H(t)],$$

gdzie $H(t)$ oznacza skumulowaną funkcję hazardu. W miejsce nieznanego $H(t)$ podstawia się estymator Nelsona–Aalena

$$\hat{H}(t) = \sum_{j:t_{(j)} \leq t} \frac{d_j}{r_j},$$

co prowadzi do estymatora Fleminga–Harringtona:

$$\tilde{S}_{FH}(t) = \exp\left(-\sum_{j:t_{(j)} \leq t} \frac{d_j}{r_j}\right), \qquad 0 \leq t \leq t_{(n)}. \tag{2}$$

Wykres (2) przedstawia estymator Fleminga-Harringtona dla funkcji przeżycia.

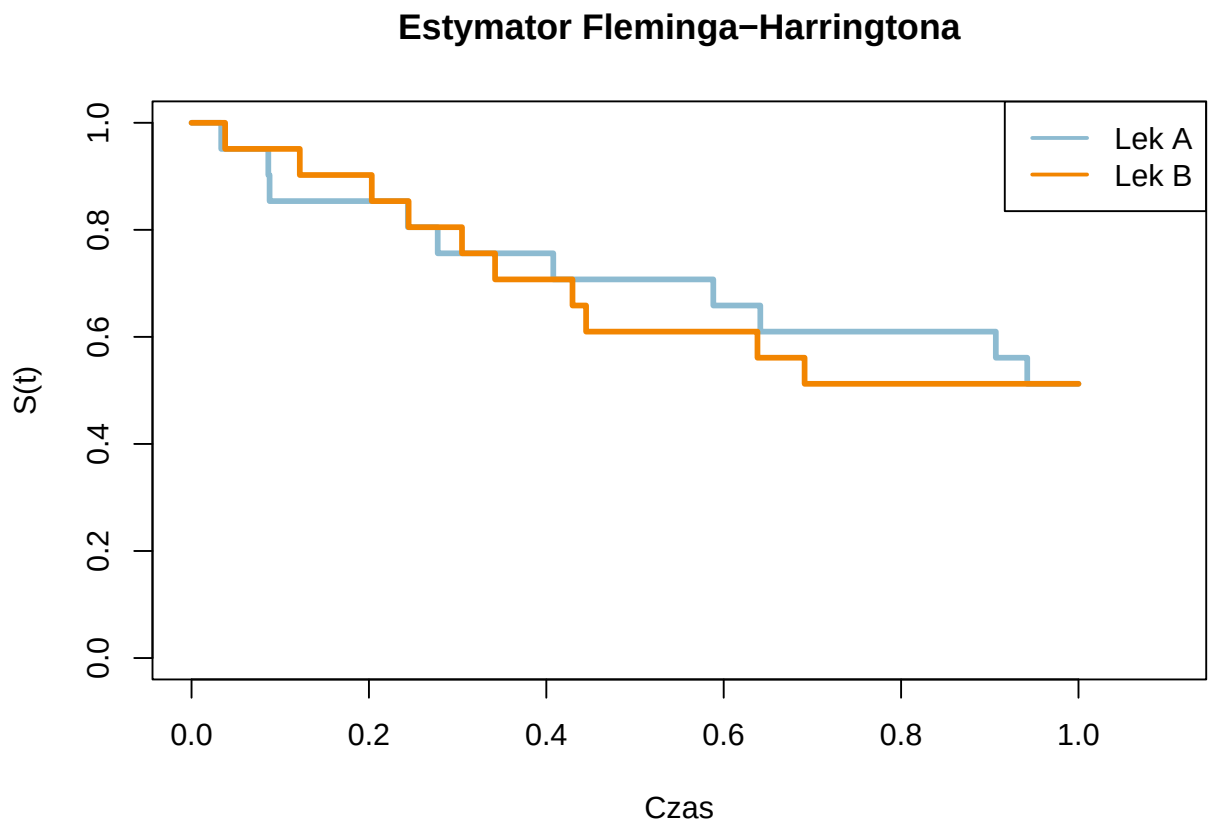

Rysunek 2: Wykres estymatora Fleminga-Harringtona funkcji przeżycia

Na podstawie estymatora Fleminga–Harringtona krzywe dla leków A i B przebiegają bardzo podobnie, a różnice między nimi są niewielkie i niesystematyczne. Nie widać wyraźnej przewagi żadnego z leków, dlatego można przypuszczać, że ich działanie jest zbliżone.

1.2 Zadanie 2

Napisany został program do tworzenia wykresu estymatora Kaplana-Meiera z "ogonem" estymowanym zgodnie z propozycją Browna, Hollandera i Kowara, o którym mowa jest na wykładzie 5. Za pomocą tego programu naszkicowano wykresy (numery wykresów) estymatorów funkcji przeżycia do remisji choroby pacjentów leczonych lekiem A oraz lekiem B na podstawie danych opisanych w zadaniu 3 z listy 2.

W przypadku, gdy największa zaobserwowana wartość czasu t^+ odpowiada obserwacji ocenzurowanej, estymator Kaplana–Meiera $\hat{S}(t)$ nie jest określony dla $t > t^+$

Brown, Hollander i Kowar (1974) zaproponowali wówczas, aby „ogon" estymatora $\hat{S}(t)$ uzupełnić funkcją przeżycia odpowiednio dobranego rozkładu wykładniczego. Konstrukcja ta polega na dopasowaniu takiej funkcji przeżycia, która w punkcie t^+ przyjmuje dokładnie wartość estymatora Kaplana–Meiera, tj.

$$\exp(-\vartheta t^+) = \hat{S}(t^+)$$

Z powyższego równania wynika jednoznacznie parametr rozkładu wykładniczego:

$$\vartheta = -\frac{\ln\left(\hat{S}(t^+)\right)}{t^+}$$

Stąd otrzymujemy, że w przypadku estymatora Browna, Hollandera i Kowara

$$\hat{S}(t) = \exp\left[\frac{\ln\left(\hat{S}(t^+)\right)}{t^+} t\right], \quad \text{dla } t > t^+$$

```r
est.KM.ogon <- function(fit, t.max = NULL, n = 300){
  t <- fit$time
  S <- fit$surv
  t.plus <- tail(t, 1)
  S.plus <- tail(S, 1)

  # przedłużamy wykres
  if (is.null(t.max)) t.max <- 5 * t.plus
  grid <- seq(0, t.max, length.out = n)

  # funkcja schodkowa KM
  S.km <- stepfun(t, c(1, S))
  S.grid <- S.km(grid)

  # sprawdzenie, czy ostatnia obserwacja była cenzurowana
  last.event  <- tail(fit$n.event, 1)
  last.censor <- tail(fit$n.censor, 1)

  if (last.event == 0 && last.censor > 0) {
    theta <- -log(S.plus) / t.plus
    idx <- grid > t.plus
    S.grid[idx] <- exp(-theta * grid[idx])
  }
  data.frame(time = grid, surv = S.grid)
}
```

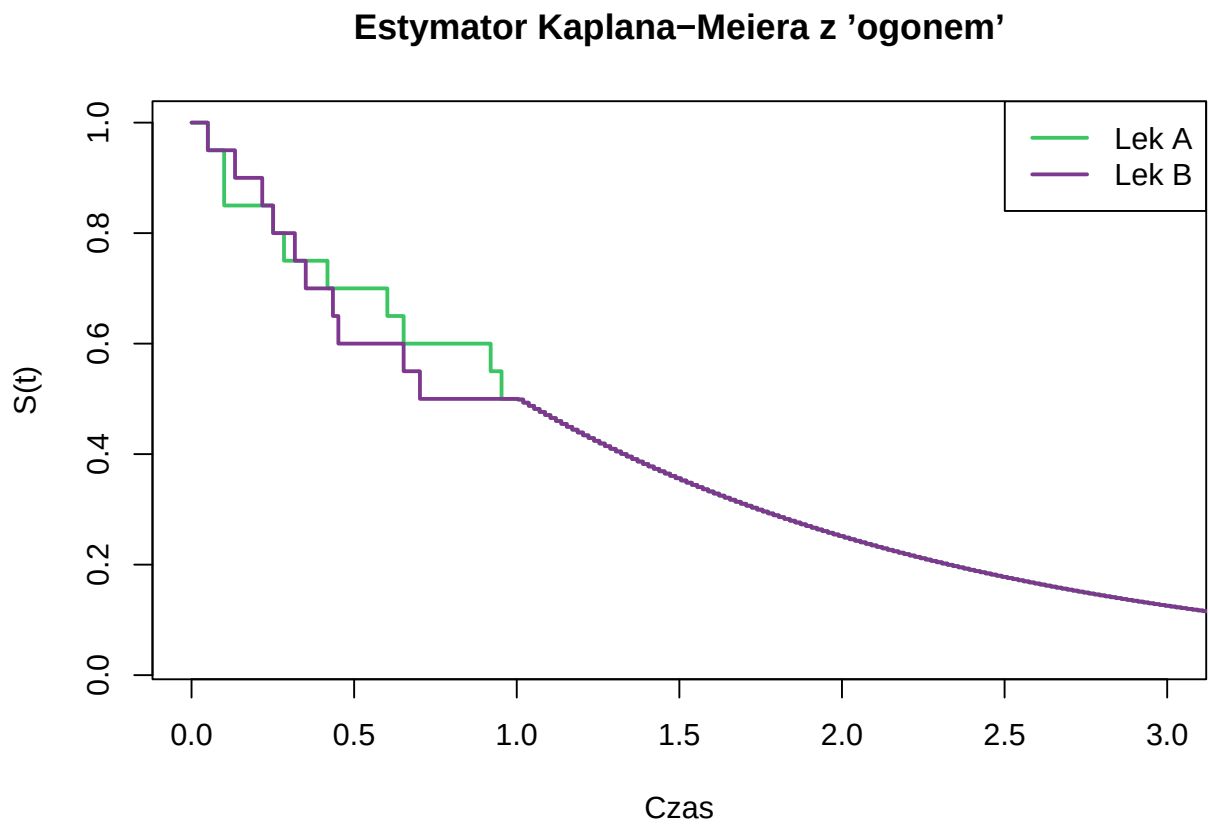

Rysunek 3: Wykres estymatora Kaplana-Meiera wraz z 'ogonem'

Wykres (3) przedstawia estymatory Kaplana–Meiera dla leków A i B wraz z „ogonem" estymowanym zgodnie z propozycją Browna–Hollandera–Kowara. Część schodkowa odpowiada zaobserwowanym remisjom, natomiast poziome zakończenie przy $t = 1$ wynika z cenzurowania pacjentów bez remisji. Dla $t > 1$ funkcja przeżycia została przedłużona wykładniczo. W części początkowej widoczne są różnice między terapiami, natomiast ogon jest identyczny, gdyż obie grupy mają tę samą wartość estymatora KM w punkcie t^+.

1.3 Zadanie 3

Przeprowadzona została symulacja polegająca na wygenerowaniu $M = 1000$ zbiorów danych cenzurowanych I-go typu z uogólnionego rozkładu wykładniczego $\mathcal{GE}(\alpha, \lambda)$ dla $\alpha = 2, \lambda = 0.5$ (funkcja została wykorzystana z zadania 1a z listy 2) dla trzech prób: $n = 30, 50, 100$. Punkt t_0 został ustalony jako wartość oczekiwana przyjętego modelu. Dla każdej próby oszacowano wartości funkcji przeżycia w punktach t_0 oraz $2t_0$, wykorzystując estymator Kaplana–Meiera z „ogonem" uzupełnionym zgodnie z propozycją Browna-Hollandera-Kowara. Otrzymane oszacowania zestawiono w postaci histogramów (rysunek 4). Pozwoli nam to sprawdzić, czy estymator Kaplana-Meiera jest asymptotycznie normalny w punkcie t_0 oraz $2t_0$.

```
# zad 1a lista 2
qgexp <- function(p, alpha, lambda){
  f.kwantylowa <- -(1/lambda)*log(1 - p^(1/alpha))
  return(f.kwantylowa)
}
generuj.GE.cenzurowane1 <- function(n, alpha, lambda, t0){
  losowe.liczby <- runif(n)
  probka <- sapply(losowe.liczby, FUN = function(u) qgexp(u, alpha, lambda))
  probka <- sort(probka)
```

```r
  ocenzurowane <- rep(1, length.out = n)
  ocenzurowane[probka > t0] <- 0
  probka[ocenzurowane == 0] <- t0
  df <- data.frame(probka = probka,
                   ocenzurowane = ocenzurowane)

  return(df)
}
```

```r
# symulacja zadania 3
symuluj_dane <- function(n, alpha, lambda, t0, M = 1000){

  S.t0  <- numeric(M)
  S.2t0 <- numeric(M)

  for (m in 1:M){
    dane <- generuj.GE.cenzurowane1(n, alpha, lambda, t0)
    fit  <- survfit(Surv(probka, ocenzurowane) ~ 1, data = dane)
    est  <- est.KM.ogon(fit, t.max = 2*t0)

    idx1 <- which.min(abs(est$time - t0))
    idx2 <- which.min(abs(est$time - 2*t0))

    S.t0[m]  <- est$surv[idx1]
    S.2t0[m] <- est$surv[idx2]
  }

  tibble(
    est = c(S.t0, S.2t0),
    punkt = rep(c("t0", "2t0"), each = M),
    n = paste0("n=", n)
  )
}

set.seed(123)
lambda <- 0.5
alpha  <- 2

t0 <- (1/lambda) * gamma(1 + 1/alpha)

wyn30  <- symuluj_dane(30,  alpha, lambda, t0)
wyn50  <- symuluj_dane(50,  alpha, lambda, t0)
wyn100 <- symuluj_dane(100, alpha, lambda, t0)

wyniki <- bind_rows(wyn30, wyn50, wyn100)
```

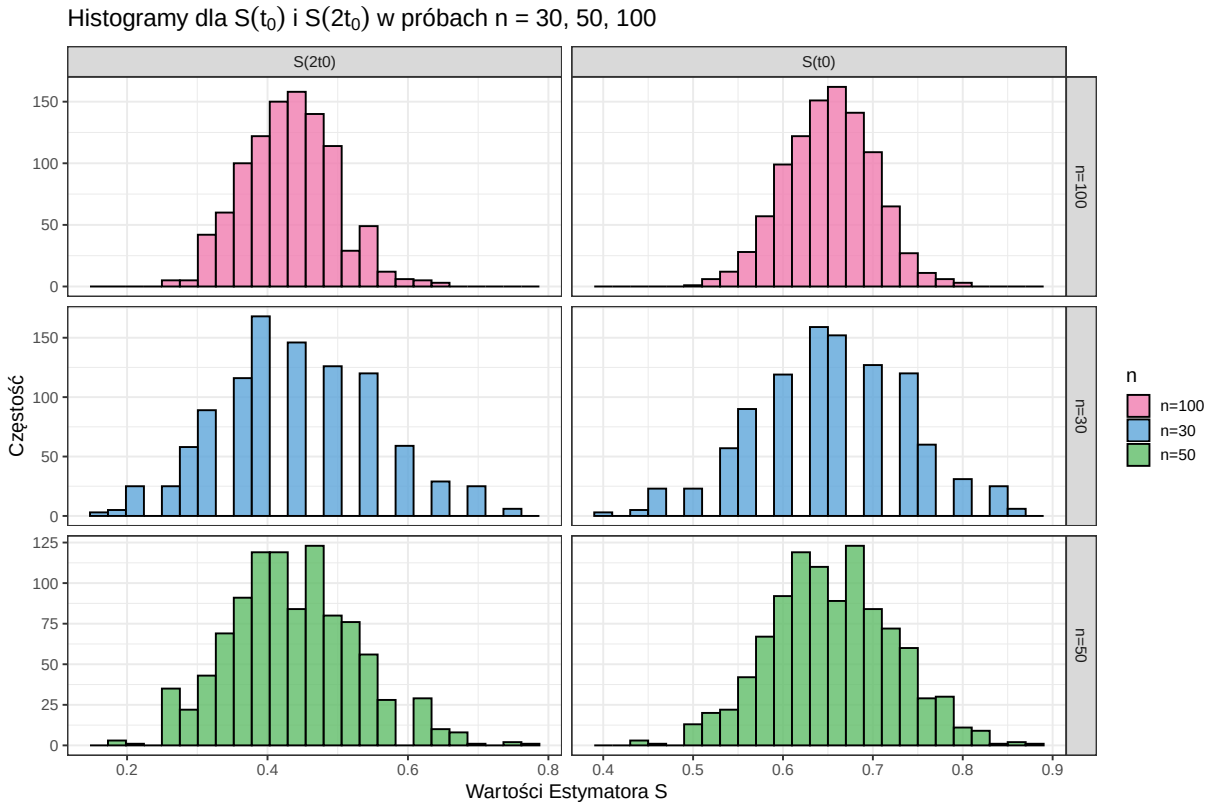

Rysunek 4: Wykres oszacowania wartości funkcji przeżycia w punktach t_0 i $2t_0$ dla estymatora Kaplana-Meiera

Na podstawie histogramów widać, że wraz ze wzrostem liczności próby rozkład oszacowań staje się coraz bardziej symetryczny i zbliżony do normalnego. Dla $n = 100$ kształt najbardziej przypomina rozkład normalny w punktach t_0, $2t_0$. Zatem możemy stwierdzić, że estymator Kaplana-Meiera dla rozkładu $\mathcal{GE}(2, 0.5)$ jest asymptotycznie normalny w punkcie t_0 oraz $2t_0$.

2 Lista 6

2.1 Zadanie 1

W tym zadaniu napisano program, który estymuje średni czas życia w oparciu o estymator Kaplana-Meiera oraz Fleminga-Herringtona. Do każdego z nich zastosowano oszacowanie ogona (wykładniczego) zaproponowanego przez Browna, Hollandera i Kowara.

a) Estymator średniego czasu życia Kaplana-Meiera

Chcemy obliczyć

$$\hat{\mu} = \int_0^\infty \hat{S}(t)\, dt.$$

Ponieważ estymator Kaplana–Meiera jest funkcją schodkową, całkę rozbijamy na dwa składniki:

- I_1 - całka po schodkach na przedziale $\left(0, t^+\right]$
- I_2 - ogon wykładniczy dla $t > t^+$

Najpierw I_1 czas skoków oznaczmy jako

$$0 = t_0 < t_1 < t_2 < \ldots < t_k = t^+,$$

Wartości na lewych krańcach oznaczmy jako

$$\hat{S}_0(t) = 1, \quad \hat{S}_1(t), \hat{S}_2(t), \ldots, \hat{S}_{k-1}(t)$$

Wtedy na każdym przedziale $(t_{j-1}, t_j]$, dla $j = 1, 2, \ldots, k$ funkcja przeżycia jest stała, więc:

$$\int_{t_{j-1}}^{t_j} \hat{S}(t)dt = \hat{S}_{j-1}(t)(t_j - t_{j-1})$$

Stąd I_1 ma postać:

$$I_1 = \sum_{j=1}^{k} \hat{S}_{j-1}(t)(t_j - t_{j-1})$$

Teraz część I_2. Wiemy, że wykładnicza funkcja przeżycia dla $t > t^+$ jest postaci

$$\hat{S}(t^+) = \exp(\vartheta t^+)$$

Stąd mamy

$$\int_{t^+}^{\infty} e^{-\vartheta t} dt = \frac{\exp(\vartheta t^+)}{\vartheta} = \frac{\hat{S}(t^+)}{\vartheta}$$

Zatem nasz estymator średniego czasu życia wygląda następująco:

$$\hat{\mu} = I_1 + I_2$$

Poniżej przedstawiono program do obliczenia estymatora średniego czasu życia w oparciu o estymator Kaplana-Meiera.

```r
est.sr.czas.KM <- function(fit){
  widths <- diff(c(0, fit$time))
  survs <- c(1, fit$surv[-length(fit$surv)])
  I1 <- sum(widths * survs)

  last.event  <- tail(fit$n.event, 1)
  last.censor <- tail(fit$n.censor, 1)

  I2 <- 0
  if(last.event == 0 && last.censor > 0){
    t_plus <- tail(fit$time, 1)
    S_plus <- tail(fit$surv, 1)
    theta  <- -log(S_plus) / t_plus
    I2     <- S_plus / theta
  }
  return(I1+I2)
}
```

b) Estymator średniego czasu życia Fleminga-Herringtona

Tutaj estymator ma postać

$$\tilde{\mu} = \int_0^\infty \tilde{S}(t)\, dt.$$

Ponieważ $\tilde{S}(t)$ jest również funkcją schodkową, całkę liczymy analogicznie jak w punkcie a), wprowadzając składniki I_1 (całka po schodkach) oraz I_2 (ogon wykładniczy Browna–Hollandera–Kowara). Ostatecznie:

$$\tilde{\mu} = I_1 + I_2.$$

Poniżej przedstawiono program do obliczenia estymatora średniego czasu życia w oparciu o estymator Fleminga–Harringtona.

```r
est.sr.czas.FH <- function(fit){

  widths <- diff(c(0, fit$time))
  survs  <- c(1, fit$surv[-length(fit$surv)])
  I1     <- sum(widths * survs)

  last.event  <- tail(fit$n.event, 1)
  last.censor <- tail(fit$n.censor, 1)

  I2 <- 0
  if(last.event == 0 && last.censor > 0){
    t_plus <- tail(fit$time, 1)
    S_plus <- tail(fit$surv, 1)
    theta  <- -log(S_plus) / t_plus
    I2     <- S_plus / theta
  }
  return(I1 + I2)
}
```

2.2 Zadanie 2

W oparciu o dane z zadania 3 z listy 2 oszacowano średni czas życia dla obu leków w oparciu o estymator Kaplana-Meiera oraz Fleminga-Herringtona.

Na przedstawionej tabeli (1) przedstawiono wyniki estymacji średniego czasu życia.

Tabela 1: Oszacowanie średniego czasu remisji dla leków A i B

Metoda	Lek A	Lek B
Kaplan–Meier	1.432	1.394
Fleming–Harrington	1.484	1.447

Można zauważyć, że średni czas remisji jest nieco dłuższy dla leku A niż dla leku B, niezależnie od użytego estymatora. Zarówno estymator średniego czasu życia w oparciu o estmator Kaplana-Meiera jak i Fleming–Harrington dają bardzo zbliżone wyniki, a różnice między metodami są niewielkie i nie zmieniają ogólnego wniosku o przewadze leku A.

3 Lista 7

3.1 Zadanie 1

Celem zadania jest przygotowanie programu, który dla zadanego poziomu ufności $1-\alpha$ oraz wybranej wartości $\tau > 0$ konstruuje przedział ufności dla średniego czasu życia

Estymator średniego czasu życia do chwili τ definiujemy jako

$$\hat{\mu}_\tau = \int_0^\tau \hat{S}(t)dt$$

Wariancję estymatora $\hat{\mu}_\tau$ szacujemy jako

$$\widehat{V}(\hat{\mu}_\tau) = \sum_{i=1}^{D} \left[\int_{s_i}^{\tau} \hat{S}(t)\,dt\right]^2 \frac{d_i}{r_i(r_i-d_i)},$$

gdzie D jest liczbą danych niecenzurowanych, $s_1 < s_2 < \cdots < s_D$ są uporządkowanymi czasami zdarzeń.

Przedział ufności na poziomie $1-\alpha$ ma postać

$$T_L = \hat{\mu}_\tau - z_{1-\alpha/2}\sqrt{\widehat{V}(\hat{\mu}_\tau)}, \qquad T_U = \hat{\mu}_\tau + z_{1-\alpha/2}\sqrt{\widehat{V}(\hat{\mu}_\tau)},$$

```r
przedzial.srednia <- function(time, status, alpha = 0.05, tau){
  fit <- survfit(Surv(time, status) ~ 1, type = "kaplan-meier")

  t  <- fit$time
  S  <- fit$surv
  d  <- fit$n.event
  r  <- fit$n.risk

  # Uwzględniamy tylko punkty t <= tau
  idx.tau <- which(t <= tau)
  t.trunc <- t[idx.tau]
  S.trunc <- S[idx.tau]

  # estymator \hat{mu}
  widths <- diff(c(0, t.trunc, tau))
  survs  <- c(1, S.trunc)
  mu.hat <- sum(widths * survs)


  cum.int <- cumsum(widths * survs)
  boundaries <- c(t.trunc, tau)

  V.hat <- 0

  idx.events <- which(d > 0 & t <= tau & r > d)

  for(i in idx.events){
    s_i <- t[i]
```

```
    j   <- which(boundaries == s_i)
    int_si_tau <- mu.hat - cum.int[j]

    V.hat <- V.hat + (int_si_tau^2) * d[i] / (r[i] * (r[i] - d[i]))
  }

  z <- qnorm(1 - alpha/2)
  se <- sqrt(V.hat)

  TL <- mu.hat - z * se
  TU <- mu.hat + z * se

  return(c(lower = TL, upper = TU))
}
```

3.2 Zadanie 2

Wykorzystując funkcję z zadania 1 oraz dane z zadania 2, wyznaczono realizacje przedziałów ufności na poziomie 0.95 dla średniego czasu do progresji choroby, osobno dla pacjentek z niskim i wysokim stopniem zaawansowania. Obliczeń dokonano dla dwóch wartości τ: dla pacjentek z niskim stopniem zaawansowania przyjęto $\tau = 1300$ i $\tau = 1600$, natomiast dla pacjentek z wysokim stopniem zaawansowania $\tau = 1200$ i $\tau = 1500$.

Wyniki zostały przedstawione w tabeli (2).

Tabela 2: Realizacje przedziałów ufności dla średniego czasu do progresji choroby

Stopień zaawansowania choroby	τ	Przedział ufności	Długość
niski	1300	[534.081, 1119.163]	585.082
niski	1600	[617.719, 1368.859]	751.140
wysoki	1200	[249.423, 524.486]	275.063
wysoki	1500	[232.733, 593.675]	360.941

Z przedstawionych wyników można zaobserwować, że długości realizacji przedziałów ufności w grupie pacjentek z niskim stopniem zaawansowania choroby są większe niż w grupie o wyższym stopniu zaawansowania. Ponadto w obu grupach przedziały ufności stają się szersze dla większych wartości τ, co wynika z faktu, że estymacja średniego czasu do progresji obejmuje wówczas dłuższy zakres czasowy oparty na mniejszej liczbie obserwacji.

4 Lista 8

4.1 Zadanie 1

Na podstawie danych z zadania 2 z listy 7 przeprowadzono weryfikację hipotezy o zgodności rozkładów czasu do progresji choroby w dwóch grupach pacjentek, przy poziomie istotności $\alpha = 0.05$. W analizie wykorzystano cztery testy nieparametryczne: log-rank, Gehana–Breslowa, Tarone'a–Ware'a oraz Peto–Peto, a następnie porównano otrzymane wartości *p-value*.

```
dane <- rbind(
  transform(dane_niski,  grupa = "niski"),
  transform(dane_wysoki, grupa = "wysoki")
)
dane$grupa <- factor(dane$grupa, levels = c("niski", "wysoki"))

test <- function(type.label){
  wynik <- logrank_test(
    Surv(time, status) ~ grupa,
    data = dane,
    type = type.label,
    distribution = "asymptotic"
  )
  pvalue(wynik)
}

wyniki_pval <- c(
  logrank       = test("logrank"),
  GehanBreslow  = test("Gehan-Breslow"),
  TaroneWare    = test("Tarone-Ware"),
  PetoPeto      = test("Peto-Peto")
)
```

W poniższej tabeli (3) przedstawiono wartości *p-value* dla podanych wcześniej testów.

Tabela 3: Wartość poziomu krytycznego *p-value* dla poszczególnych testów

Test	Wartość poziomu krytycznego
log-rank	0.0194
Gehana–Breslowa	0.1336
Tarone'a–Warego	0.0552
Peto–Peto	0.0978

Jak można zauważyć, test log-rank odrzucił hipotezę zerową na poziomie istotności $\alpha = 0.05$. W pozostałych testach nie ma podstaw do odrzucania tej hipotezy. Zaobserwować można także sporą różnicę wartości poziomu krytycznego dla każdego z testów. Różnice te mogą wynikać z odmiennymi funkcjami wag. Szczegółowe omówienie wpływu funkcji wag na otrzymane wyniki znajduje się w zadaniu drugim z listy 8 (rysunek 6).

4.2 Zadanie 2

Wykres (5) przedstawia estymator Kaplana-Meiera dla obu grup pacjentek (dane z zadania 2 z listy 7).

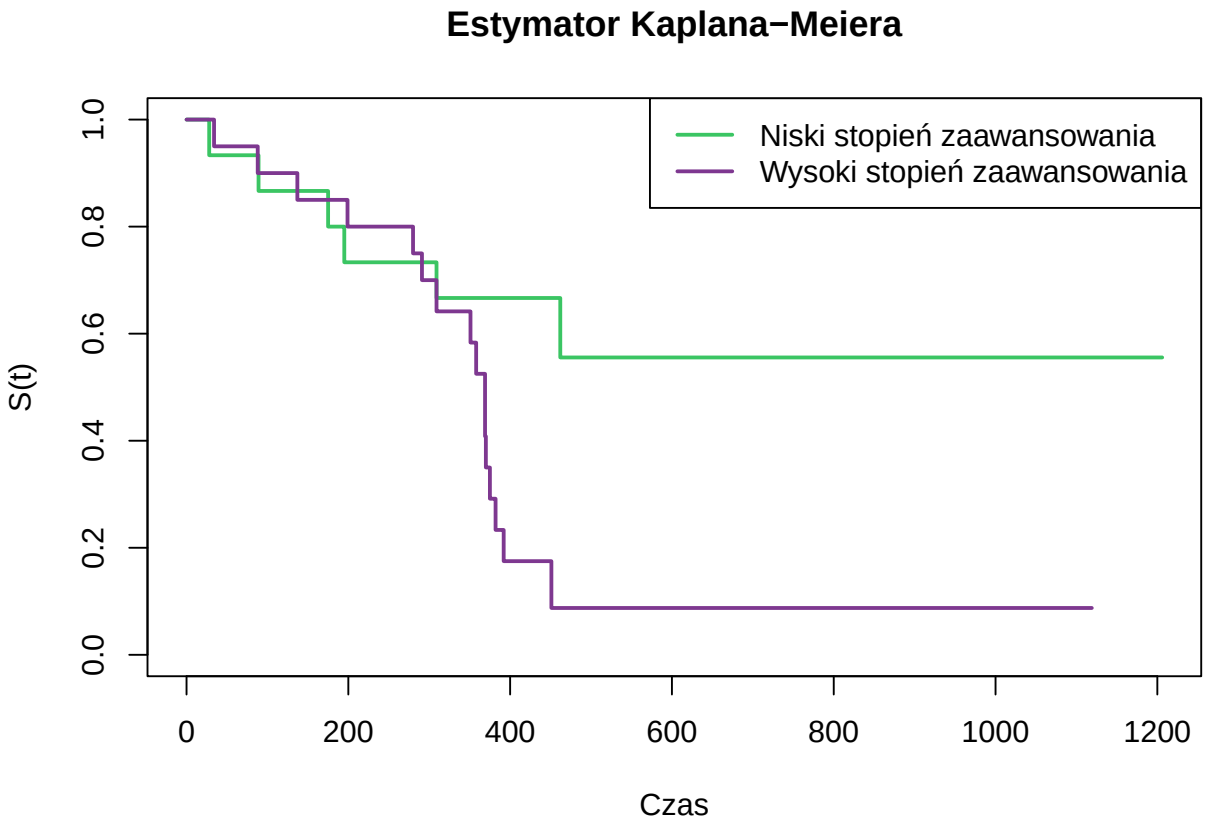

Rysunek 5: Estymatory Kaplana-Meiera dla obu grup pacjentek.

Z wykresu widać wyraźnie, że pacjentki z wysokim stopniem zaawansowania choroby charakteryzują się szybszym spadkiem funkcji przeżycia. Mocny spadek jest już około po czasie 250. Progresja następuje u nich wcześniej i częściej. W grupie o niskim stopniu zaawansowania krzywa opada wolniej, co wskazuje na dłuższy czas do progresji choroby.

Niech D oznacza liczbę różnych czasów zdarzeń, $0 < t_1 < t_2 < \ldots < t_D$ będą uporządkowanymi rosnąco czasami, w których wystąpiły zdarzenia. r_i – liczbę jednostek w ryzyku tuż przed t_i w obu grupach, d_i – liczba zdarzeń w chwili t_i, $d_i = \sum_{j=1}^{k} d_{ij}$ - łączna liczba zdarzeń w czasie t_i, $r_i = \sum_{j=1}^{k} r_{ij}$ - łączna liczba liczba jednostek w stanie ryzyka w czasie t_i.

Statystyki testowe do weryfikacji hipotezy zerowej H_0 o jednakowym rozkładzie czasów życia w dwóch grupach są oparte na ważonej sumie różnic między zaobserwowaną a oczekiwaną liczbą zdarzeń w każdej chwili t_i. Ogólna postać statystyki $Z_j(\tau)$ dla każdej grupy dla funkcji wagowej $W(t_i)$ ma postać:

$$Z_j(\tau) = \sum_{i=1}^{D} W(t_i) \left(d_{ij} - r_{ij} \frac{d_i}{r_i} \right), \quad j = 1, \ldots, k$$

Każdy test korzysta z innej funkcji wagowej:

- test log-rank: $W(t_i) = 1$
- test Gehana–Breslowa: $W(t_i) = r_i$
- test Tarone'a-Warego: $W(t_i) = \sqrt{r_i}$
- test Peto-Peto: $W(t_i) = \hat{S}(t_i) := \prod_{t_j \leq t_i} \left(1 - \frac{d_j}{r_j+1}\right)$

Dla każdej z tych wag dokonajmy normalizacji, w sensie dla każdego $w_1, \ldots, w_n$ mamy $V_i = \frac{w_i}{\sum_{i=1}^n w_i}$, gdzie $\sum_{i=1}^n V_i = 1$.

```
czasy <- sort(unique(dane$time[dane$status == 1]))

r.i <- sapply(czasy, function(ti) sum(dane$time >= ti))
d.i <- sapply(czasy, function(ti) sum(dane$time == ti & dane$status == 1))

# log-rank
w.logrank <- rep(1, length(czasy))

# Gehan{Breslow
w.gb <- r.i

# Tarone{Ware
w.tw <- sqrt(r.i)

# Peto{Peto
S.pp <- numeric(length(czasy))
for(i in seq_along(czasy)){
  if(i == 1){
    S.pp[i] <- 1 - d.i[i] / (r.i[i] + 1)
  } else {
    S.pp[i] <- S.pp[i-1] * (1 - d.i[i] / (r.i[i] + 1))
  }
}
w.pp <- S.pp

# normalizacja wag
norm <- function(v) v / sum(v)

w.logrank <- norm(w.logrank)
w.gb      <- norm(w.gb)
w.tw      <- norm(w.tw)
w.pp      <- norm(w.pp)
```

Poniższy wykres (6) przedstawia wykresy funkcji wagowych dla poszczególnych testów.

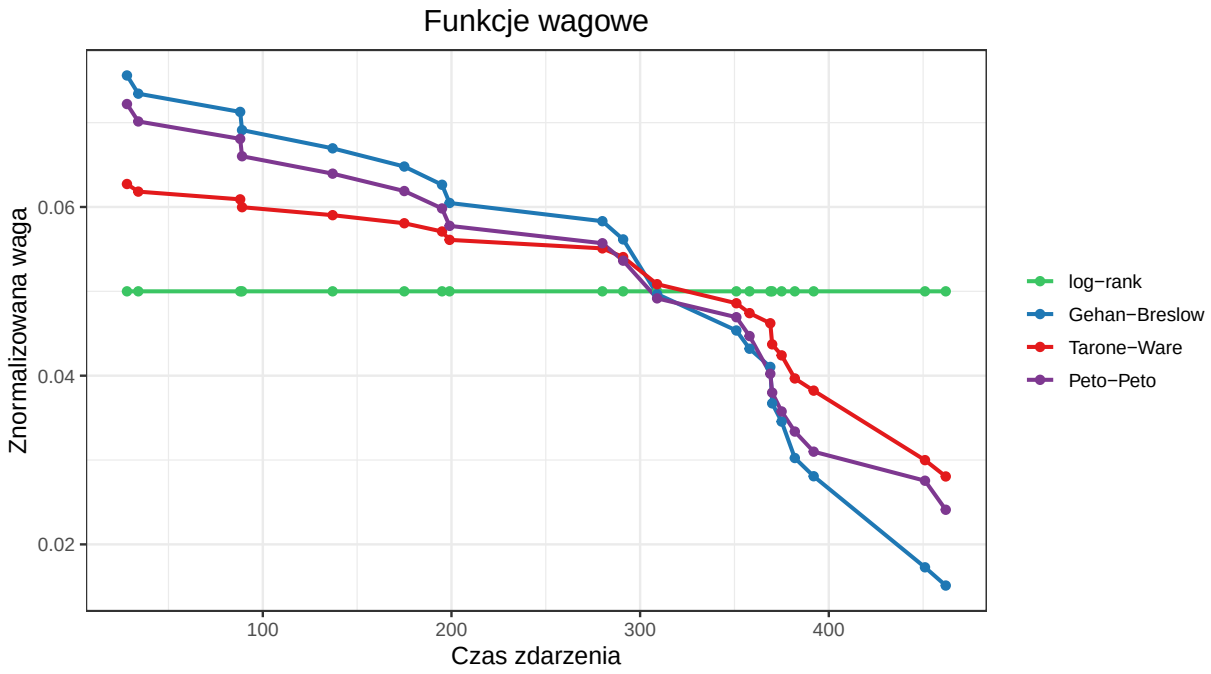

Rysunek 6: Wykres znormalizowanych funkcji wagowych dla poszczególnych testów

Z wykresu można zaobserwować, że agi testów Gehana–Breslowa, Peto–Peto oraz Tarone'a–Warego mają charakter malejący w czasie, podczas gdy funkcja wagowa testu log-rank pozostaje stała na całym rozważanym przedziale.

Taka konstrukcja wag wyjaśnia otrzymane wcześniej wartości *p-value* (tabela 3). Różnice między grupami pacjentek są najbardziej widoczne w późniejszych etapach obserwacji, dlatego test log-rank, który silnie reaguje także na późne rozbieżności, daje najmniejszą wartość p i prowadzi do odrzucenia hipotezy zerowej. Z kolei testy o wagach malejących są mniej czułe na różnice pojawiające się w późnym okresie — większy nacisk kładą na początkowe fragmenty krzywych, gdzie rozbieżności między grupami są niewielkie. To tłumaczy, dlaczego ich wartości *p-value* są wyższe i nie prowadzą do odrzucenia hipotezy zerowej.