Raport 3

Analiza przeżycia

Kacper Haczkiewicz, nr albumu 277515

2026-02-03

Spis treści

1 Lista 9 **2**
1.1 Zadanie 1 2
1.2 Zadanie 2 2
1.3 Zadanie 3 2
1.4 Zadanie 4 3
1.5 Zadanie 5 4
1.6 Zadanie 6 5
1.7 Zadanie 7 5
1.8 Zadanie 8 7
1.9 Zadanie 9 8

2 Lista 10 **9**
2.1 Zadanie 1 9
2.2 Zadanie 2 9
2.3 Zadanie 3 9
2.4 Zadanie 4 10
2.5 Zadanie 5 12
2.6 Zadanie 6 13

3 Lista 11 **14**
3.1 Zadanie 1 14
3.2 Zadanie 2 14
3.3 Zadanie 3 14
3.4 Zadanie 4 15
3.5 Zadanie 5 17
3.6 Zadanie 6 18

4 Lista 12 **19**
4.1 Zadanie 2 20
4.2 Zadanie 3 21
4.3 Zadanie 4 23

1 Lista 9

1.1 Zadanie 1

W tym zadaniu oszacowano parametry modelu przyspieszonego czasu awarii. Jako zmienną zależną przyjęto *time*, a charakterystyki następująco: *age, sex, ph.ecog, ph.karno.*

```
dane <- lung[, c("time", "status", "age", "sex", "ph.ecog", "ph.karno")]
dane <- na.omit(dane)

dane$age_c <- dane$age - mean(dane$age)
dane$ph.karno_c <- dane$ph.karno - mean(dane$ph.karno)

dane$sex <- as.factor(dane$sex)
dane$ph.ecog <- as.factor(dane$ph.ecog)

model.aft <- survreg(Surv(time, status) ~
                     age_c + sex + ph.ecog + ph.karno_c,
                     data=dane, dist = "weibull")
```

Współczynniki tego modelu są pokazane na poniższej tabeli.

Tabela 1: Oszacowania współczynników modelu AFT dla rozkładu Weibulla

Charakterystyka	beta	exp(beta)
Wyraz wolny	-6.3012	0.0018
Wiek	0.0086	1.0086
Płeć=2 (kobieta)	-0.4083	0.6648
PH.Ecog1	0.4216	1.5244
PH.Ecog2	0.9261	2.5246
PH.Ecog3	1.6872	5.4043
PH.Karno	0.0101	1.0102

1.2 Zadanie 2

Interpretacja współczynników w modelu przyspieszonego czasu awarii opiera się na czynniku przyspieszenia czasu, czyli na $\exp(\beta)$ (gdzie ich wartości są w tabeli 1).

Dla charakterystyki płeć (kobieta względem mężczyzny) otrzymano wartość $\exp(\beta) < 1$, o oznacza wydłużenie oczekiwanego czasu życia w porównaniu z grupą referencyjną. Dla pozostałych charakterystyk wartości $\exp(\beta) > 1$, co wskazuje na przyspieszenie wystąpienia zdarzenia, a tym samym skrócenie czasu życia. Wyraz wolny nie podlega interpretacji jako czynnik przyspieszenia.

1.3 Zadanie 3

W tym zadaniu oszacowano funkcję przeżycia (w dniach) odpowiadającej rozkładowi czasu życia kobiety w wieku 70 lat o charakterystyce ph.ecog=1 i ph.karno=90. Na podstawie tych danych obliczono prawdopodobieństwo, że czas życia tej kobiety będzie większy niż 300 dni.

```
age_mean <- mean(dane$age)
karno_mean <- mean(dane$ph.karno)
```

```r
z1 <- c(
  70 - age_mean,    # age_c
  1,                # sex2
  1,                # ph.ecog1
  0,                # ph.ecog2
  0,                # ph.ecog3
  90 - karno_mean   # ph.karno_c
)



mu <- model.aft$coefficients[1]

gamma <- model.aft$coefficients[-1]
beta  <- -gamma

sigma <- model.aft$scale
alpha <- 1 / sigma

lambda <- exp(-mu * alpha)


# funkcja przeżycia
S_aft <- function(t, z, beta, alpha, lambda){
  linpred <- sum(beta * z)
  exp( - lambda * exp(alpha * linpred) * t^alpha )
}

# Pr(T > 300)
S_300 <- S_aft(
  t = 300,
  z = z1,
  beta = beta,
  alpha = alpha,
  lambda = lambda
)
```

Z obliczeń wyszło, że estymowane prawdopodobieństwo czasu życia dłużej niż 300 dni u tej kobiety wynosi 0.581.

1.4 Zadanie 4

Na rysunku 1 przedstawiono wykres estymowanej funkcji przeżycia z zadania 3.

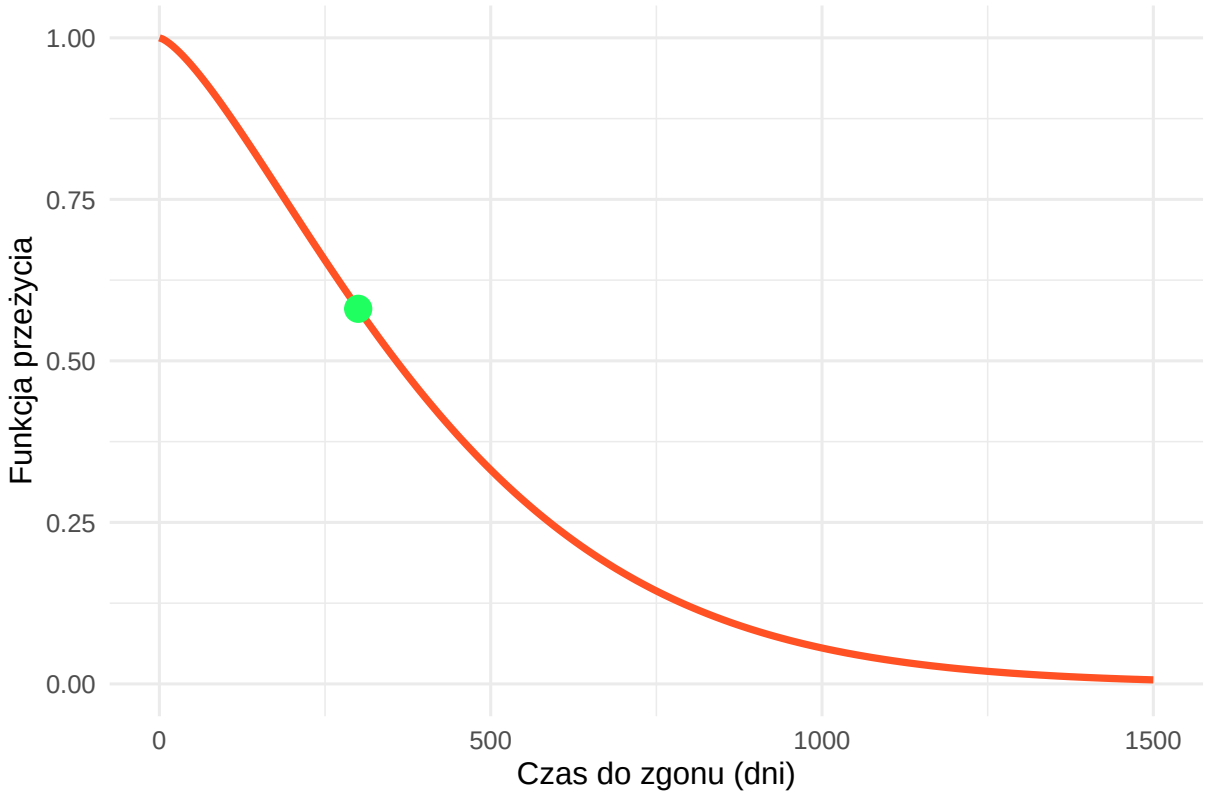

Rysunek 1: Estymacja funkcji przeżycia - AFT

Można zauważyć, że funkcja przeżycia maleje o wiele szybciej do 500 dnia, potem zaś prędkość maleje. Punktem zielonym zaznaczono wartość, która odpowiada wynikowi z zadania 3.

1.5 Zadanie 5

W tym zadaniu oszacowano parametry dla modelu proporcjonalnych hazardów. Tak jak w zadaniu pierwszym, jako zmienną zależną przyjęto *time*, a charakterystyki następująco: *age, sex, ph.ecog, ph.karno*.

```
model.ph <- phreg(
  Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c,
  data = dane,
  dist = "weibull"
)
```

W tabeli 2 przedstawiono współczynniki modelu.

Tabela 2: Oszacowania współczynników modelu PH dla rozkładu Weibulla

Charakterystyka	beta	exp(beta)
Wiek	0.0119	1.0120
Płeć=2 (kobieta)	-0.5665	0.5675
PH.Ecog1	0.5850	1.7950
PH.Ecog2	1.2851	3.6150
PH.Ecog3	2.3413	10.3947
PH.Karno	0.0140	1.0141
log(scale)	6.3012	545.2258
log(shape)	0.3276	1.3876

1.6 Zadanie 6

Na podstawie oszacowanego modelu proporcjonalnych hazardów (tabela 2) z rozkładem Weibulla stwierdzono, że dla charakterystyk *age, ph.ecog1, ph.ecog2, phecog3, ph.karno* wartości ilorazów hazardów spełniają $\exp(\beta) > 1$ co wskazuje na zwiększenie intensywności zdarzenia, a tym samym szybsze wystąpienie zgonu wraz ze wzrostem tych zmiennych. Efekt ten jest szczególnie silny dla wyższych poziomów zmiennej *ph.ecog3*, gdzie hazard rośnie wielokrotnie w porównaniu do grupy referencyjnej.

Z kolei dla charakterystyki *sex* mamy warunek $\exp(\beta) < 1$, co oznacza zmniejszenie hazardu względem grupy referencyjnej i wskazuje na wolniejsze tempo wystąpienia zdarzenia.

Parametry `log(scale)` i `log(shape)` określają odpowiednio skalę i kształt bazowego rozkładu Weibulla przyjętego w modelu.

1.7 Zadanie 7

W tym zadaniu wyznaczono oszacowania funkcji hazardu (w dniach) odpowiadające rozkładowi czasu życia 70-letnich kobiet o tej samej wartości wskaźnika Karnofsky'ego równej 90, lecz o zróżnicowanym stanie ogólnym opisanym charakterystyką ph.ecog, przyjmującą wartości 1 oraz 2. Zmienne ciągłe zostały wcześniej wycentrowane względem średnich w próbie.

Dla obu przypadków narysowano wykresy oszacowanych funkcji hazardu (rysunek 2), a także wykresy logarytmów tych funkcji (rysunek 3).

```
beta <- model.ph$coefficients[1:6]
alpha <- exp(model.ph$coefficients["log(shape)"])
lambda0 <- exp(model.ph$coefficients["log(scale)"])



z1 <- c(age_c = 70 - age_mean,
        sex2 = 1,
        ph.ecog1 = 1,
        ph.ecog2 = 0,
        ph.ecog3 = 0,
        ph.karno_c = 90 - karno_mean)

z2 <- c(age_c = 70 - age_mean,
        sex2 = 1,
```

```
        ph.ecog1 = 0,
        ph.ecog2 = 1,
        ph.ecog3 = 0,
        ph.karno_c = 90 - karno_mean)


hazard_ph <- function(t, z, beta, shape, scale){
  theta <- sum(beta * z)
  (shape / scale) * (t / scale)^(shape - 1) * exp(theta)
}
```

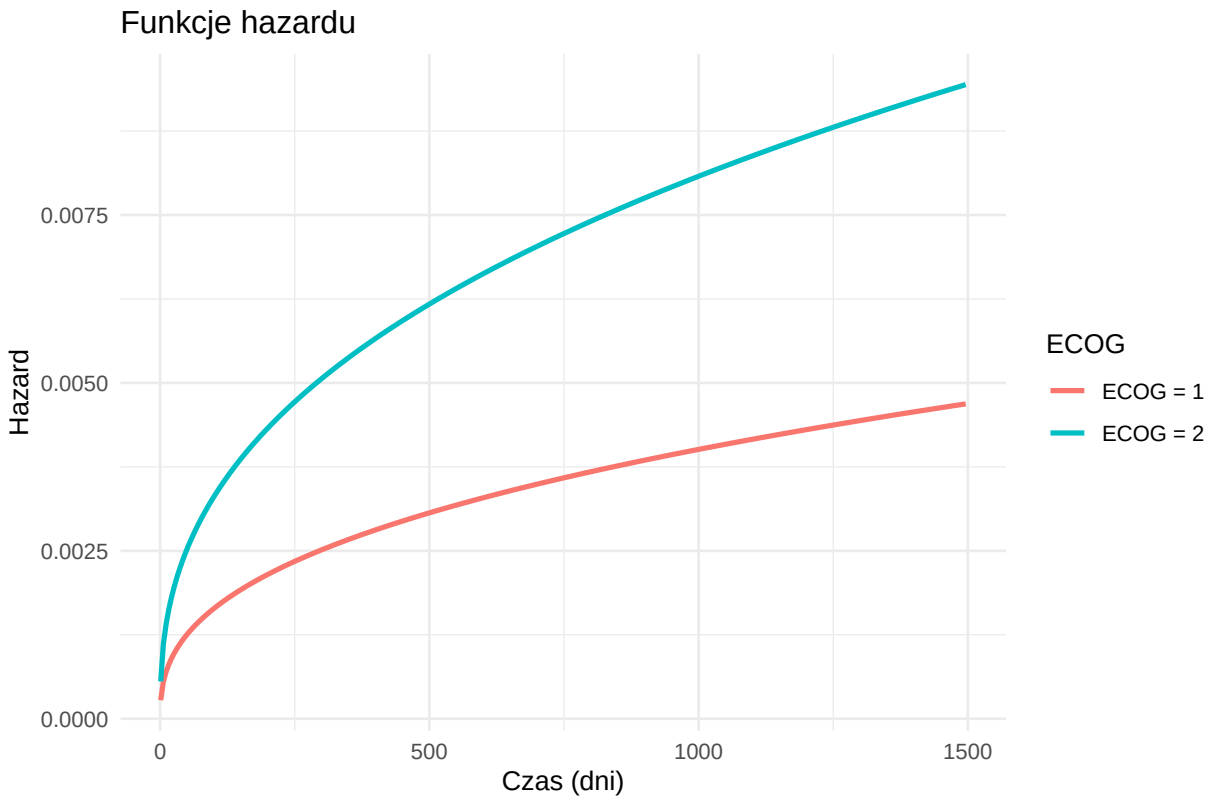

Rysunek 2: Estymowane funkcje hazardu dla odpowiednich charakterystyk 70-letnich kobiet - model PH

Wartości funkcji hazardu dla profilu ECOG = 2 dominują nad wartościami dla ECOG = 1, co wskazuje na istotnie gorsze rokowania w tej grupie. Przekłada się to na większe natężenie zgonów w każdym punkcie czasowym obserwacji, niezależnie od wieku czy pozostałych parametrów klinicznych.

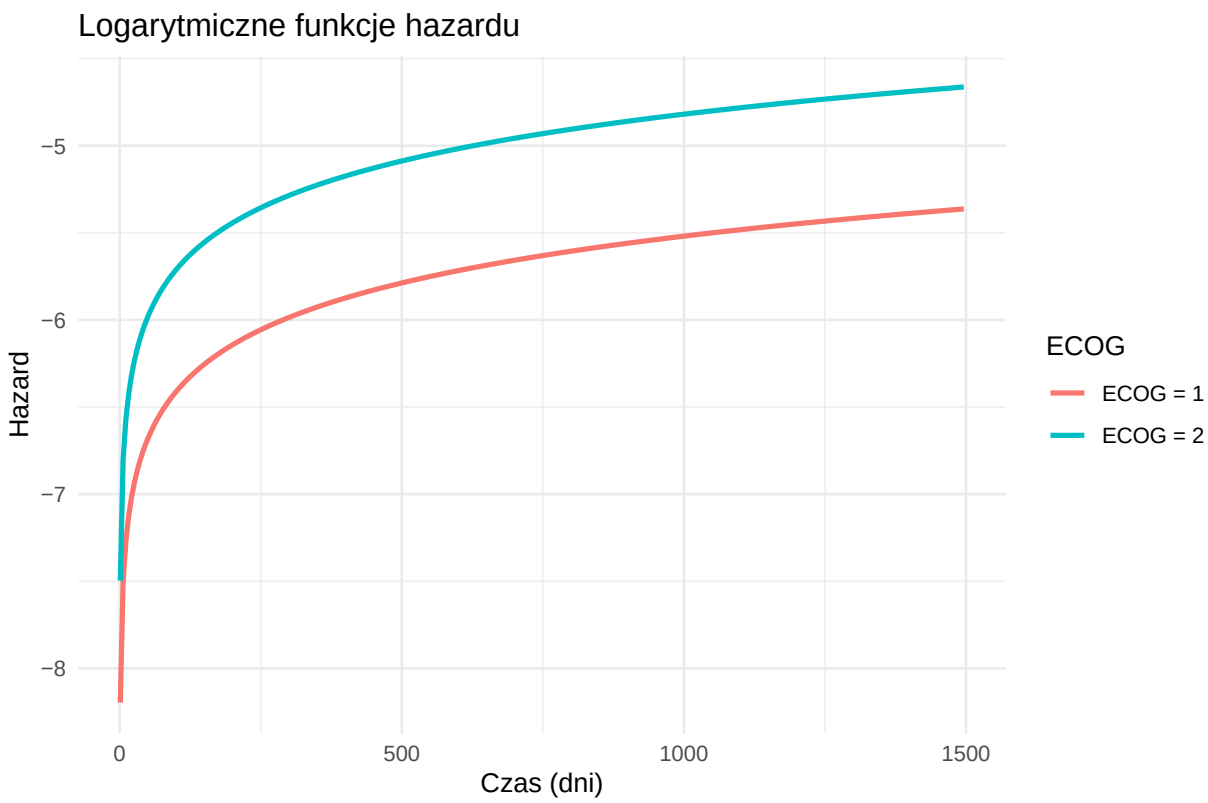

Rysunek 3: Logarytmy estymowanych funkcji hazardu dla odpowiednich charakterystyk 70-letnich kobiet - model PH

Poszczególne krzywe funkcji log-hazardu na rysunku 3 wydają się równoległe, co sugeruje, że iloraz hazardów może być stały w czasie.

1.8 Zadanie 8

W oparciu o oszacowania funkcji hazardu z zadania poprzedniego, oszacowano funkcję przeżycia.

Wiadomo, że zachodzi relacja między funkcją przeżycia, a hazardu. Skorzystamy z faktu:

Fakt 1 *Korzystając z relacji między funkcja przeżycia a funkcją hazardu*

$$S(t) = \exp\left[-\int_0^t h(u)du\right]$$

model proporcjonalnych hazardów możemy równoważnie przedstawić nastepująco

$$S(t \mid z) = \exp\left[-\int_0^t h_0(u)\exp(\beta^T z)du\right] = [S_0(t)]^{\exp(\beta^T z)}$$

Wiemy również, że dla rozkładu Weibulla mamy $S_0(t) = \exp(-\lambda t^\alpha)$

```
S.ph <- function(t, z, beta, alpha, lambda){
  S0 <- exp(-(t/lambda)^alpha)
  return(S0^(exp(sum(beta*z))))
}
```

```
pr_z1 <- S.ph(300, z1, beta, alpha, lambda0)
pr_z2 <- S.ph(300, z2, beta, alpha, lambda0)
```

Oszacowano prawdopodobieństwo, że kobieta w wieku 70 lat o podanych wcześniej charakterystykach przeżyje ponad 300 dni. Dla kobiety o stopniu sprawności ECOG 2 prawdopodobieństwo przeżycia ponad 300 dni wynosi 0.3345, a dla kobiety z ECOG 1 – 0.5806. Ten drugi wynik jest identyczny z uzyskanym w Zadaniu 3, co potwierdza, że oba modele (mimo różnej interpretacji współczynników β) definiują ten sam rozkład czasu trwania życia.

1.9 Zadanie 9

Poniżej przedstawiono oszacowanie funkcji przeżycia dla modelu PH (o którym mowa była w zadaniu 8).

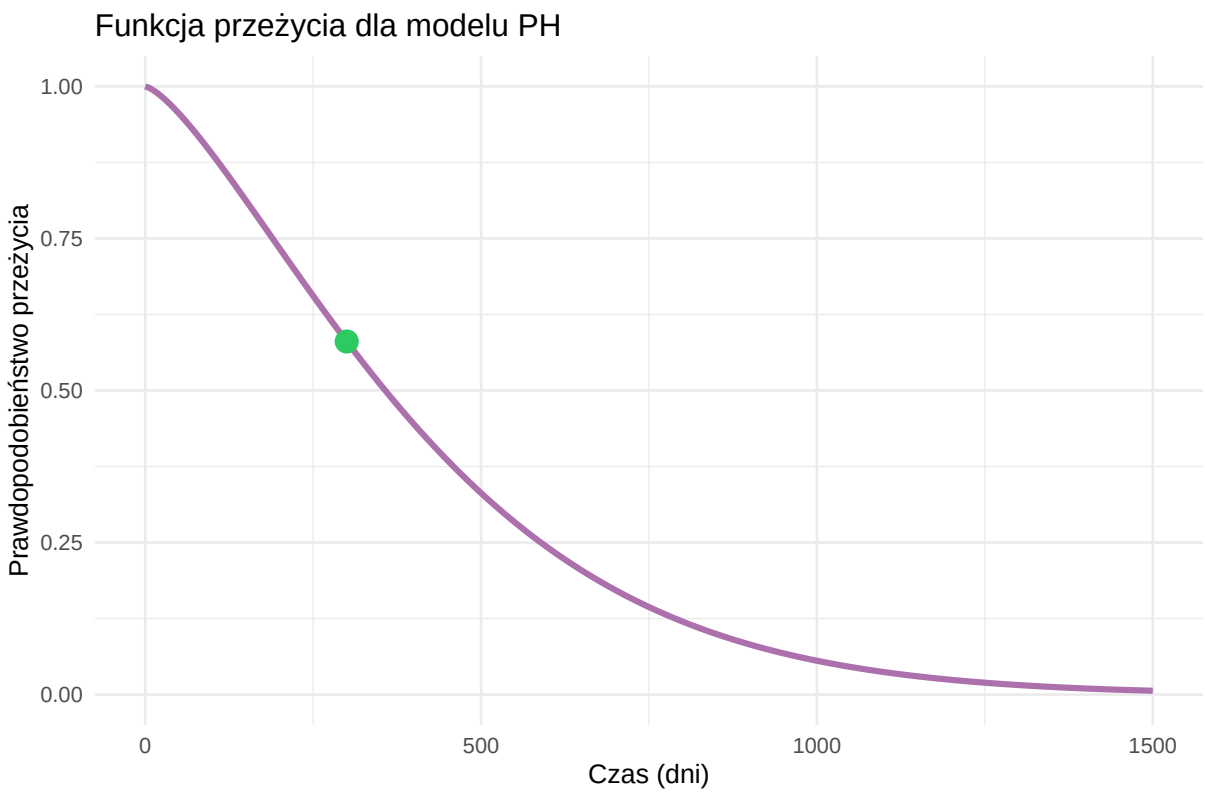

Rysunek 4: Estymacja funkcji przeżycia - PH

Jeżeli przyjrzymy się wykresowi 4 oraz 1, to można zauważyć, że są one identyczne. Jest to graficzne potwierdzenie faktu, że rozkład Weibulla należy jednocześnie do klasy modeli przyspieszonego czasu awarii (AFT) oraz proporcjonalnych hazardów (PH).

2 Lista 10

2.1 Zadanie 1

Zadanie polega na oszacowaniu parametrów modelu proporcjonalnych hazardów Coxa. Tak, jak na liscie dziewiątej, jako zmienną zależną przyjęto *time*, a za charakterystyki zmienne: *age, sex, ph.ecog, ph.karno*. W tabeli 3 przedstawione są wartości poszczególnych charakterystyk.

```
model.cox <- coxph(Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c,
                   data = dane)
```

Tabela 3: Oszacowania współczynników modelu PH Coxa dla rozkładu Weibulla

Charakterystyka	beta	exp(beta)
Wiek	0.0126	1.0127
Płeć	-0.5657	0.5680
PH.Ecog1	0.5781	1.7826
PH.Ecog2	1.2399	3.4553
PH.Ecog3	2.3959	10.9781
PH.Karno	0.0124	1.0125

2.2 Zadanie 2

Na podstawie tabeli 3 można zauważyć, że w modelu proporcjonalnych hazardów Coxa z bazowym rozkładem Weibulla stwierdzono, że wraz ze wzrostem wieku pacjenta hazard zdarzenia nieznacznie rośnie - zwiększenie wieku o jeden rok powoduje wzrost hazardu o około 1.3%, przy pozostałych zmiennych stałych. Płeć ma istotny wpływ na ryzyko zdarzenia - dla jednej z kategorii hazard jest niższy o około 43% w porównaniu do kategorii referencyjnej.

Stan sprawności pacjenta mierzony skalą ECOG istotnie zwiększa ryzyko zdarzenia: w porównaniu do poziomu referencyjnego ECOG 0, pacjenci z ECOG 1 mają hazard wyższy o około 78%, z ECOG 2 ponad trzykrotnie wyższy, natomiast dla ECOG 3 hazard jest niemal jedenastokrotnie większy. Oznacza to, że pogarszający się stan funkcjonalny pacjenta silnie skraca oczekiwany czas przeżycia.

Wskaźnik Karnofsky'ego również wpływa na ryzyko zdarzenia - wzrost jego wartości o jeden punkt wiąże się ze wzrostem hazardu o około 1.25%.

2.3 Zadanie 3

Poniżej przedstawiono oszacowanie bazowej skumulowanej funkcji hazardu i bazowej funkcji przeżycia odpowiadającej rozkładowi czasu życia.

```
# bazowa skumulowana funkcja hazardu (estymator Breslowa)
basehaz_df <- basehaz(model.cox, centered = FALSE)

# bazowa funkcja przeżycia
surv_df <- data.frame(
  time = basehaz_df$time,
  S0   = exp(-basehaz_df$hazard)
)
```

2.4 Zadanie 4

W tym zadaniu wyznaczono oszacowania skumulowanej funkcji hazardu (w dniach) odpowiadające rozkładowi czasu życia 70-letnich kobiet o tej samej wartości wskaźnika Karnofsky'ego równej 90, lecz o zróżnicowanym stanie ogólnym opisanym charakterystyką `ph.ecog`, przyjmującą wartości 1 oraz 2. Zmienne ciągłe zostały wcześniej wycentrowane względem średnich w próbie. Następnie narysowano wykresy skumulowanych funkcji hazardu oraz wykresy ich logarytmów w celu oceny zasadności założenia modelu proporcjonalnych hazardów.

```
beta <- coef(model.cox)

bh <- basehaz(model.cox, centered = TRUE)

z1 <- c(age_c = 70 - age_mean,
        sex2 = 1,
        ph.ecog1 = 1,
        ph.ecog2 = 0,
        ph.ecog3 = 0,
        ph.karno_c = 90 - karno_mean)

z2 <- c(age_c = 70 - age_mean,
        sex2 = 1,
        ph.ecog1 = 0,
        ph.ecog2 = 1,
        ph.ecog3 = 0,
        ph.karno_c = 90 - karno_mean)

theta1 <- sum(beta * z1)
theta2 <- sum(beta * z2)

scale1 <- exp(theta1)
scale2 <- exp(theta2)

H1 <- bh$hazard * scale1
H2 <- bh$hazard * scale2

df_H <- data.frame(
  t = rep(bh$time, 2),
  H = c(H1, H2),
  ECOG = factor(rep(c("ECOG = 1", "ECOG = 2"),
                    each = length(bh$time)))
)
```

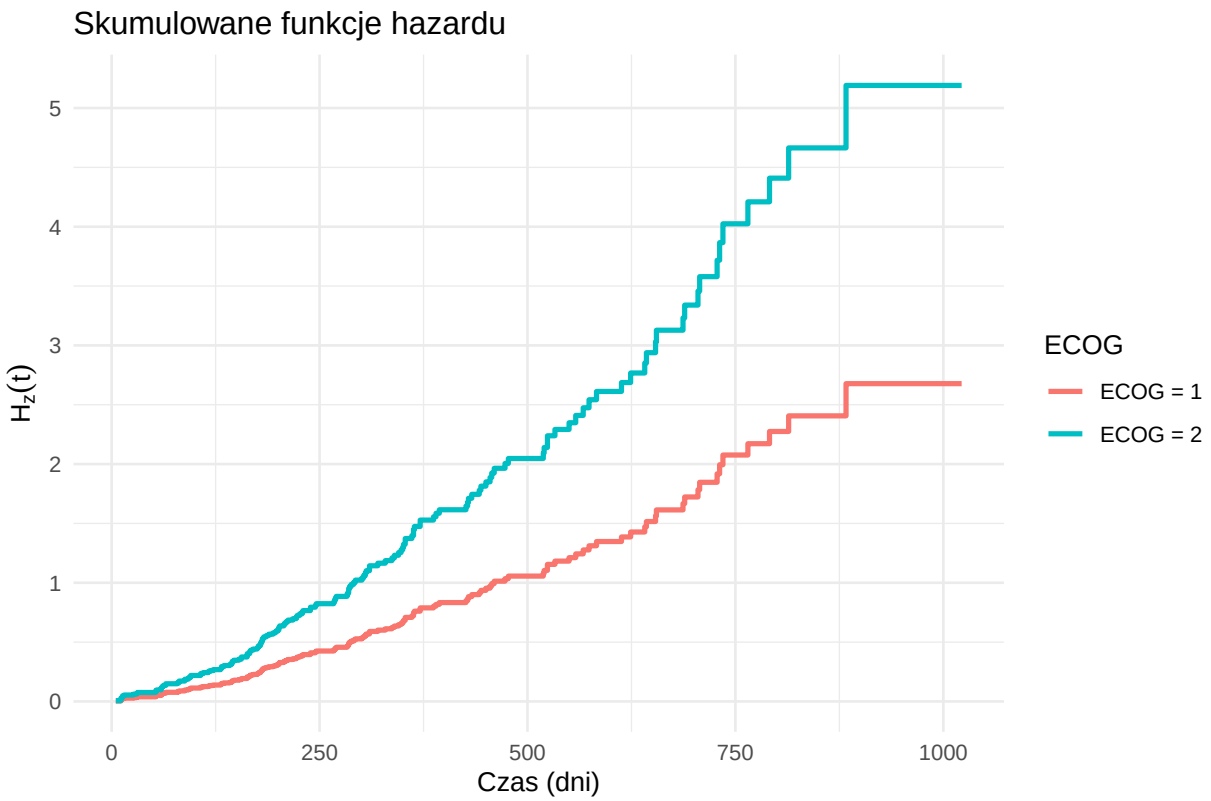

Rysunek 5: Estymowane skumulowane funkcje hazardu dla odpowiednich charakterystyk 70-letnich kobiet - model PH Coxa

Na podstawie wykresu 5 stwierdzono, że skumulowany hazard dla kobiety o charakterystyce ECOG = 2 jest większy niż dla kobiety o charakterystyce ECOG = 1. Wskazuje to, że do danego momentu czasu pacjentka z gorszym stanem ogólnym zdrowia (ECOG = 2) zgromadziła większe łączne ryzyko zgonu, co skutkuje mniejszymi wartościami odpowiadającej jej funkcji przeżycia.

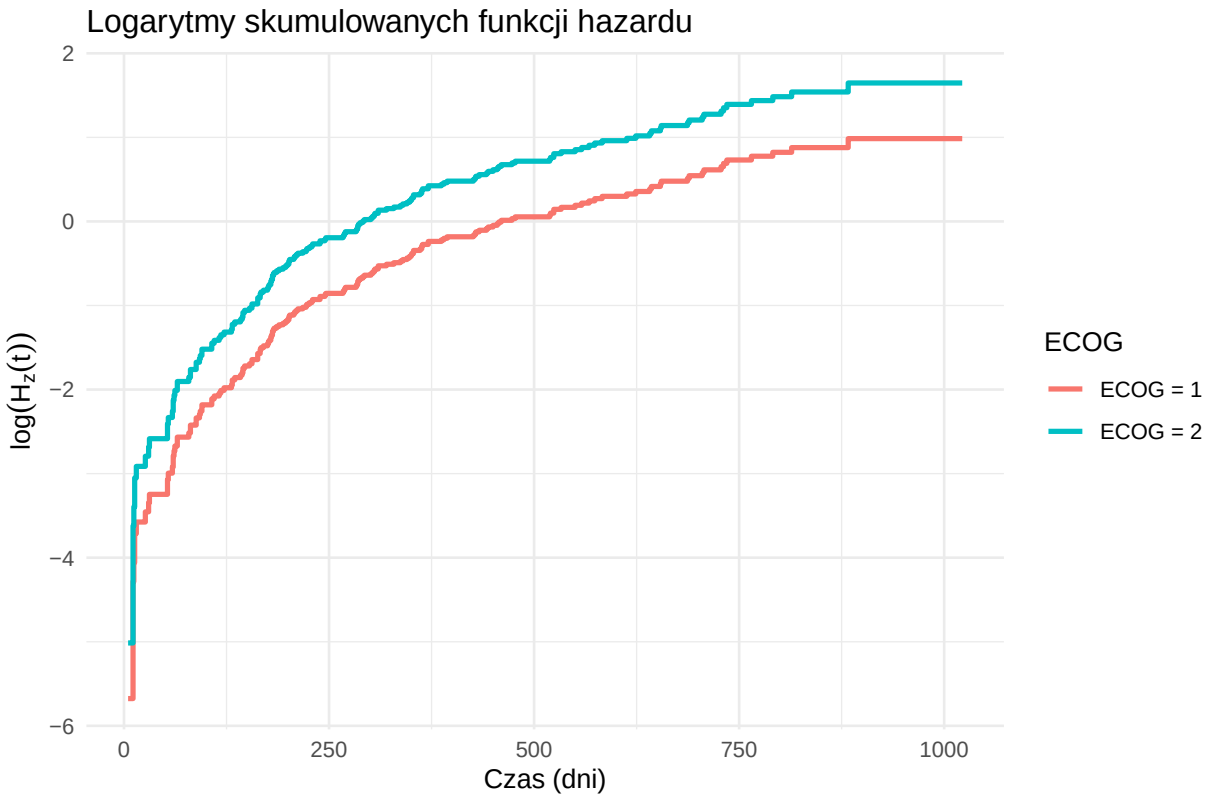

Rysunek 6: Estymowane logarytmiczne funkcje skumulowanego hazardu dla odpowiednich charakterystyk 70-letnich kobiet - model PH Coxa

Jak można zauważyć z wykresu 6, różnica pomiędzy krzywymi logarytmów skumulowanych funkcji hazardu zmienia się w czasie, szczególnie dla małych wartości czasu. Dla większych czasów (powyżej 500 dni) wykresy te wydają się być bardziej równoległe, jednak nie mają charakteru liniowego. W związku z tym można mieć pewne wątpliwości co do spełnienia założenia proporcjonalności hazardów na całym rozważanym przedziale czasowym.

2.5 Zadanie 5

Zadanie polega na oszacowaniu funkcji przeżycia (w dniach) odpowiadającej rozkładowi czasu życia 70-letnich kobiet o tej samej wartości stopnia Karnofsky'ego równej 90 oraz zróżnicowanej wartości charakterystyki ECOG wynoszącej 1 oraz 2. Dane ciągłe zostały wcześniej zcentrowane względem średnich w próbie.

W modelu Coxa funkcja przeżycia jednostki o charakterystyce z dana jest wzorem

$$S_z(t) = \exp(-H_z(t))$$

```
S.z1 <- exp(-H1)
S.z2 <- exp(-H2)

S.z1.300 <-S.z1[max(which(bh$time <= 300))]
S.z2.300 <-S.z2[max(which(bh$time <= 300))]
```

Dla kobiety o stopniu sprawności ECOG = 2 prawdopodobieństwo przeżycia ponad 300 dni wynosi 0.3598, natomiast dla kobiety o stopniu sprawności ECOG = 1 jest równe 0.5901. Drugi z otrzymanych wyników

jest bardzo zbliżony do wartości uzyskanych w zadaniach 3 oraz 8 z listy 9, która wynosi 0.5806. Różnica pomiędzy tymi oszacowaniami jest niewielka (około 0.0095), co wskazuje na zgodność uzyskanych wyników z uwzględnieniem błędu estymacji.

2.6 Zadanie 6

Poniżej przedstawiono oszacowanie funkcji przeżycia dla modelu PH Coxa (o którym mowa była w zadaniu 9) i porównanie go z wykresem funkcji przeżycia dla modelu PH (dla modelu AFT będzie taki sam jak wnioskowaliśmy).

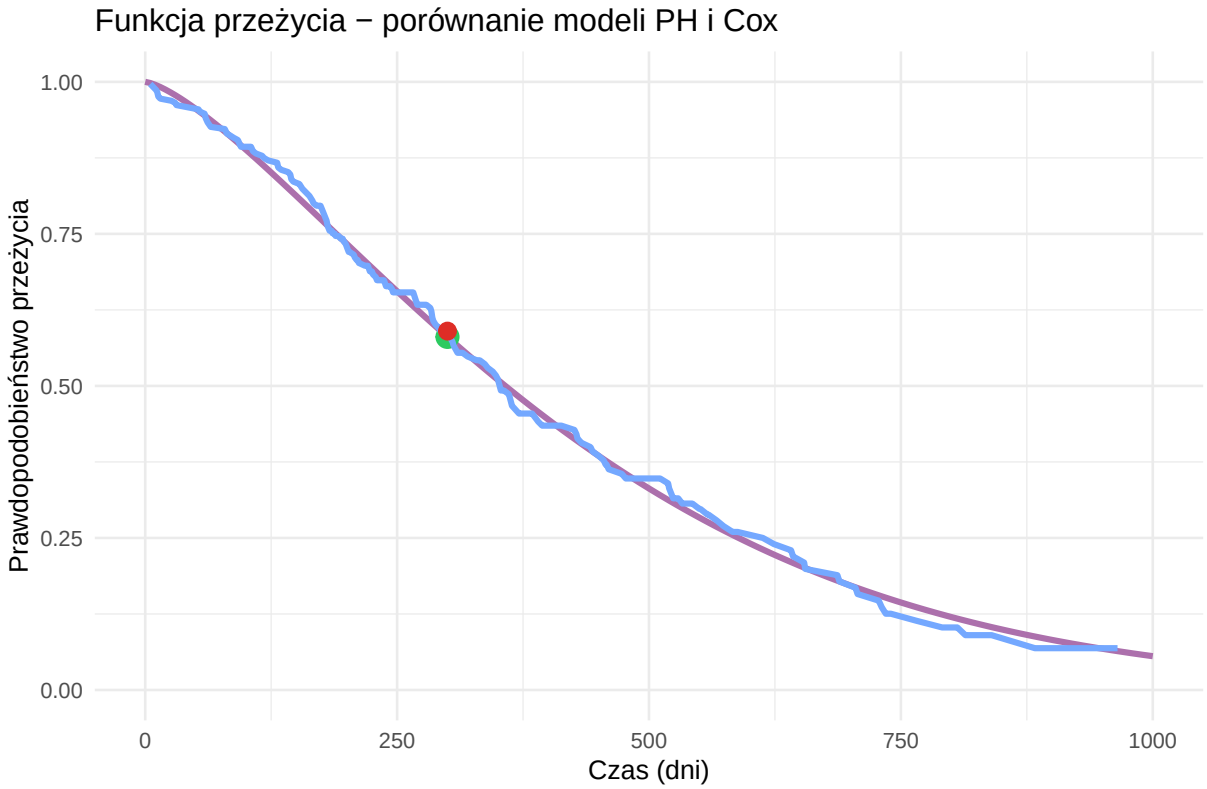

Rysunek 7: Porównanie estymowanych funkcji przeżycia - model Coxa vs model PH

Jak można zauważyć na wykresie 7, oszacowane funkcje przeżycia uzyskane w modelu Coxa oraz w modelu PH mają bardzo zbliżony przebieg w całym rozważanym przedziale czasowym. Pomimo różnic w postaci krzywych, wynikających z nieparametrycznej i parametrycznej estymacji funkcji przeżycia, oba modele prowadzą do podobnych oszacowań prawdopodobieństwa przeżycia, w szczególności dla czasu 300 dni. Może to sugerować, że przyjęte założenia parametryczne modelu PH są w tym przypadku rozsądne.

3 Lista 11

3.1 Zadanie 1

W tym zadaniu oszacowano parametry modelu proporcjonalnych szans, przyjmując za zmienną zależną zmienną time, a za charakterystyki zmienne: age, sex, ph.ecog, ph.karno. Ze względu na specyfikację funkcji, zmieniono oznaczenia statusu danych na 0 - obserwacja cenzurowana oraz 1 - dana kompletna.

```
dane$status_new <- dane$status - 1

set.seed(123)
model.po <- prop.odds(
  Event(time, status_new) ~
    age_c + sex + ph.ecog + ph.karno_c,
  data = dane,
  n.sim = 1000
)
```

Poniższa tabela **??** przedstawia wyniki oszacowań dla tego modelu.

Tabela 4: Oszacowania współczynników modelu proporcjonalnych szans

Charakterystyka	beta	exp(beta)
Wiek	0.0132	1.0133
Płeć = 2 (kobieta)	-0.9535	0.3854
PH.Ecog1	0.5470	1.7280
PH.Ecog2	1.4466	4.2487
PH.Ecog3	1.9245	6.8518
PH.Karno	-0.0037	0.9963

3.2 Zadanie 2

W modelu proporcjonalnych szans iloraz szans dwóch jednostek o różnych charakterystykach nie zależy od czasu t, a współczynniki β interpretujemy na podstawie zależności

$$\ln \frac{\theta_{z_1}(t)}{\theta_{z_2}(t)} = \beta^T (z_1 - z_2).$$

Wzrost wieku o jeden rok powoduje wzrost logarytmu ilorazu szans o 0.0132, co odpowiada zwiększeniu szansy zdarzenia o około 1.3%, przy pozostałych charakterystykach stałych.

Dla kobiet (płeć = 2) szansa zajścia zdarzenia do chwili t jest mniejsza niż dla mężczyzn — iloraz szans wynosi około 0.39. Stan sprawności opisany skalą ECOG istotnie zwiększa szanse zdarzenia: dla ECOG równym 1 są one około 1.73 razy większe, dla ECOG równym 2 ponad 4.2 razy większe, natomiast dla ECOG 3 blisko 6.9 razy większe w porównaniu do poziomu referencyjnego.

Wzrost wskaźnika Karnofsky'ego o jeden punkt prowadzi do nieznacznego zmniejszenia szansy śmierci.

3.3 Zadanie 3

Wyznaczono oszacowanie bazowej skumulowanej funkcji hazardu oraz bazowej funkcji przeżycia odpowiadającej rozkładowi czasu życia, przyjmując model proporcjonalnych szans z zadania 1.

```r
S_0 <- predict(model.po, Z = rep(0, length(model.po$gamma)))

base <- data.frame(
  time = S_0$time,
  S0   = S_0$S0,
  H0   = -log(S_0$S0)
)
```

3.4 Zadanie 4

Wyznaczono oszacowanie skumulowanej funkcji hazardu odpowiadającej rozkładowi czasu życia 70-letniej kobiety o tej samej wartości wskaźnika Karnofsky'ego równej 90, lecz o zróżnicowanym stanie ogólnym opisanym charakterystyką ph.ecog, przyjmującą wartości 1 oraz 2. Zmienne ciągłe zostały wcześniej wycentrowane względem średnich w próbie.

Dla obu przypadków narysowano wykresy oszacowanych funkcji hazardu (rysunek 8), a także wykresy logarytmów tych funkcji (rysunek 9).

```r
theta_0 <- (1 - S_0$S0) / S_0$S0

beta.po <- model.po$gamma

linpred1 <- sum(beta.po * z1)
linpred2 <- sum(beta.po * z2)

S_z1 <- 1 / (1 + theta_0 * exp(linpred1))
S_z2 <- 1 / (1 + theta_0 * exp(linpred2))

H_z1 <- -log(S_z1)
H_z2 <- -log(S_z2)
```

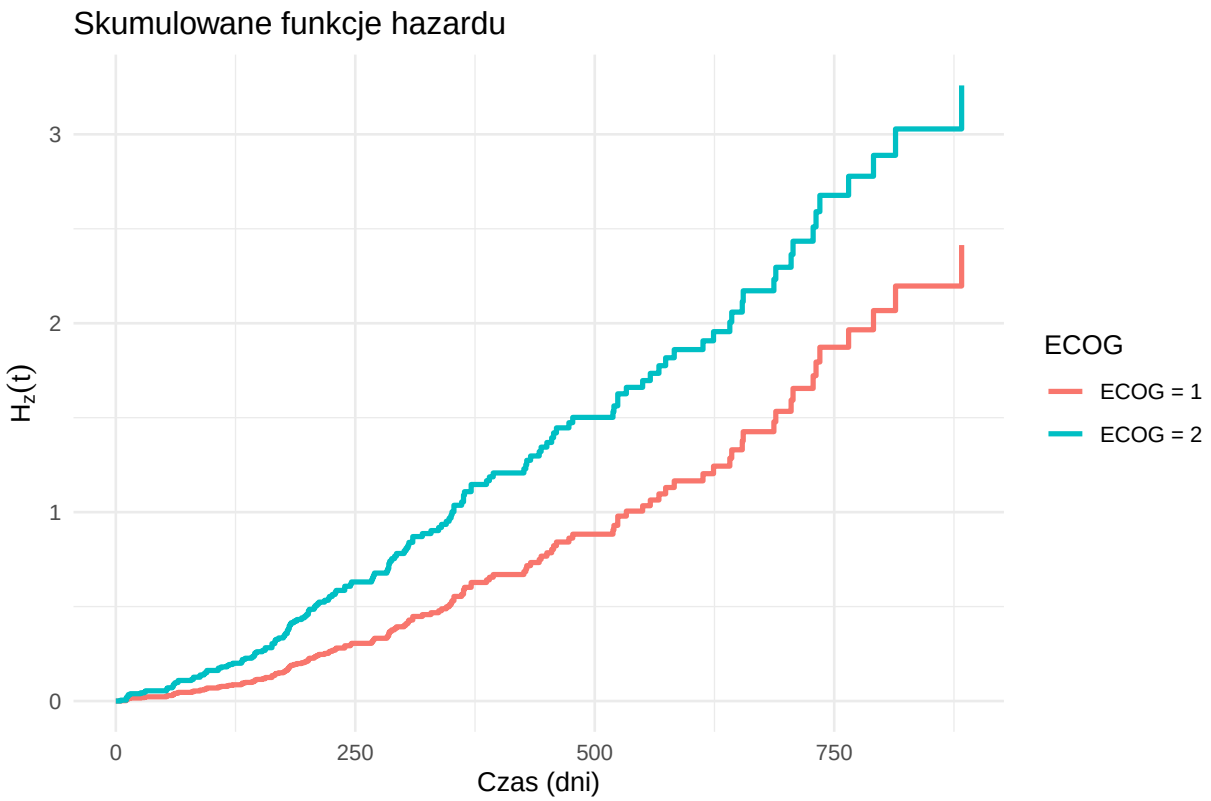

Rysunek 8: Estymowane skumulowane funkcje hazardu dla odpowiednich charakterystyk - model proporcjonalnych szans

Skumulowana funkcja hazardu dla kobiety o charakterystyce ECOG = 2 przyjmuje w całym rozważanym przedziale czasowym większe wartości niż dla kobiety o ECOG = 1, co oznacza większe łączne ryzyko zajścia zdarzenia do chwili t. Różnica pomiędzy krzywymi narasta wraz z czasem, co wskazuje na istotny wpływ stanu ogólnego pacjentki na przebieg czasu życia w modelu proporcjonalnych szans.

W modelu proporcjonalnych hazardów Coxa (rysunek 5) skumulowane funkcje hazardu dla obu profili są w przybliżeniu proporcjonalne w czasie, natomiast w modelu proporcjonalnych szans różnice pomiędzy krzywymi zmieniają się wraz z czasem. Oznacza to, że model Coxa zakłada stały iloraz hazardów, podczas gdy model proporcjonalnych szans dopuszcza jego zmienność w czasie.

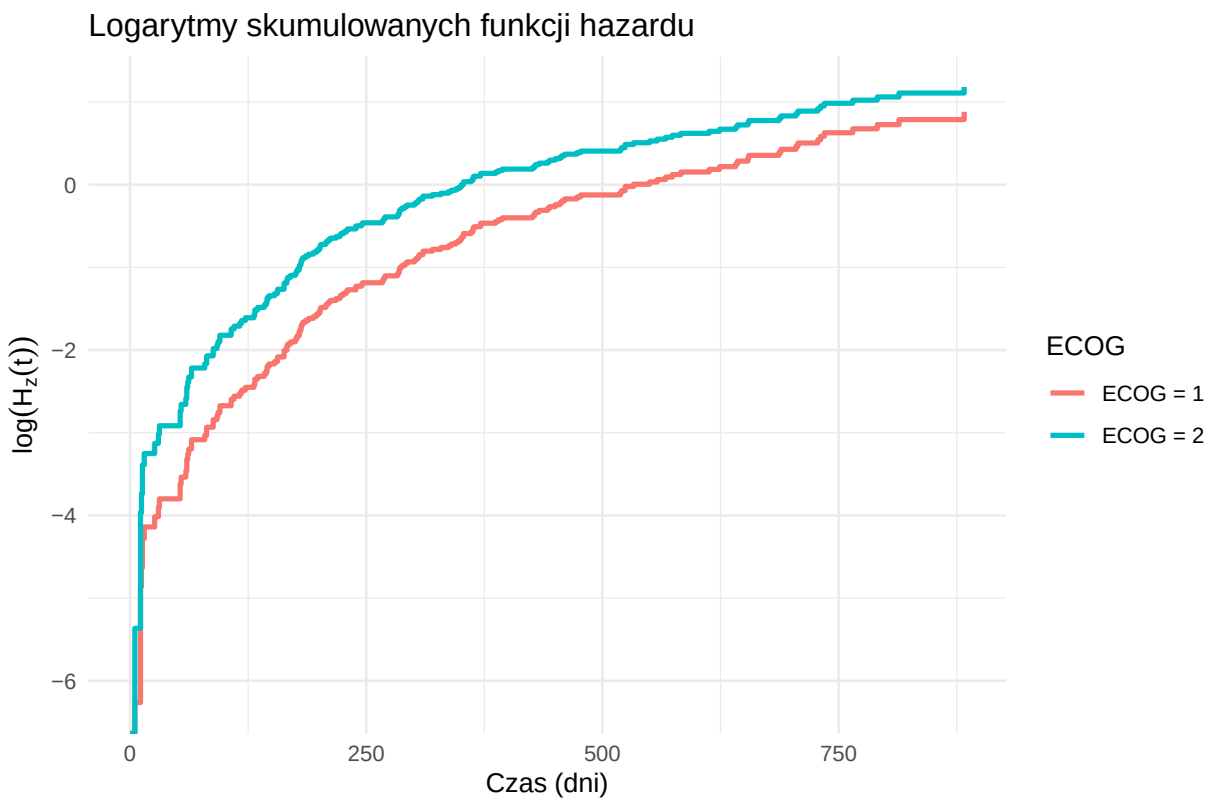

Rysunek 9: Estymowane logarytmiczne funkcje skumulowanego hazardu dla odpowiednich charakterystyk - model proporcjonalnych szans

Logarytmy skumulowanych funkcji hazardu dla obu profili mają zbliżony przebieg, jednak nie są względem siebie równoległe, co odróżnia model proporcjonalnych szans od modelu proporcjonalnych hazardów. Z czasem różnica pomiędzy krzywymi maleje, co wskazuje na zmniejszanie się względnych różnic w łącznym ryzyku zdarzenia pomiędzy rozważanymi grupami.

W porównaniu do modelu Coxa (rysunek 6) model proporcjonalnych szans daje bardzo podobny obraz ryzyka — w całym horyzoncie czasu skumulowany hazard dla ECOG = 2 pozostaje wyższy niż dla ECOG = 1.

3.5 Zadanie 5

Wyznaczono oszacowanie funkcji przeżycia (w dniach) odpowiadającej rozkładowi czasu życia kobiet opisanych powyżej. Na podstawie tego oszacowania obliczono szacowane prawdopodobieństwo, że czas życia tych kobiet będzie większy niż 300 dni.

```
S.z1.300.po <- S_z1[max(which(base$time <= 300))]
S.z2.300.po <- S_z2[max(which(base$time <= 300))]
```

Dla kobiety z ph.ecog = 1 oszacowane prawdopodobieństwo przeżycia ponad 300 dni wynosi około 0.675, natomiast dla kobiety z ph.ecog = 2 około0.4579. W porównaniu z wynikiem uzyskanym w zadaniu 5a z listy 10, oszacowanie dla modelu proporcjonalnych szans jest większe, przy czym różnica wynosi około 0.0849).

3.6 Zadanie 6

Wykres 10 przedstawia porównanie funkcji przeżycia dla pacjentki z ph.ecog = 1 (z poprzednich zadań) dla modelu Coxa oraz proporcjonalnych szans.

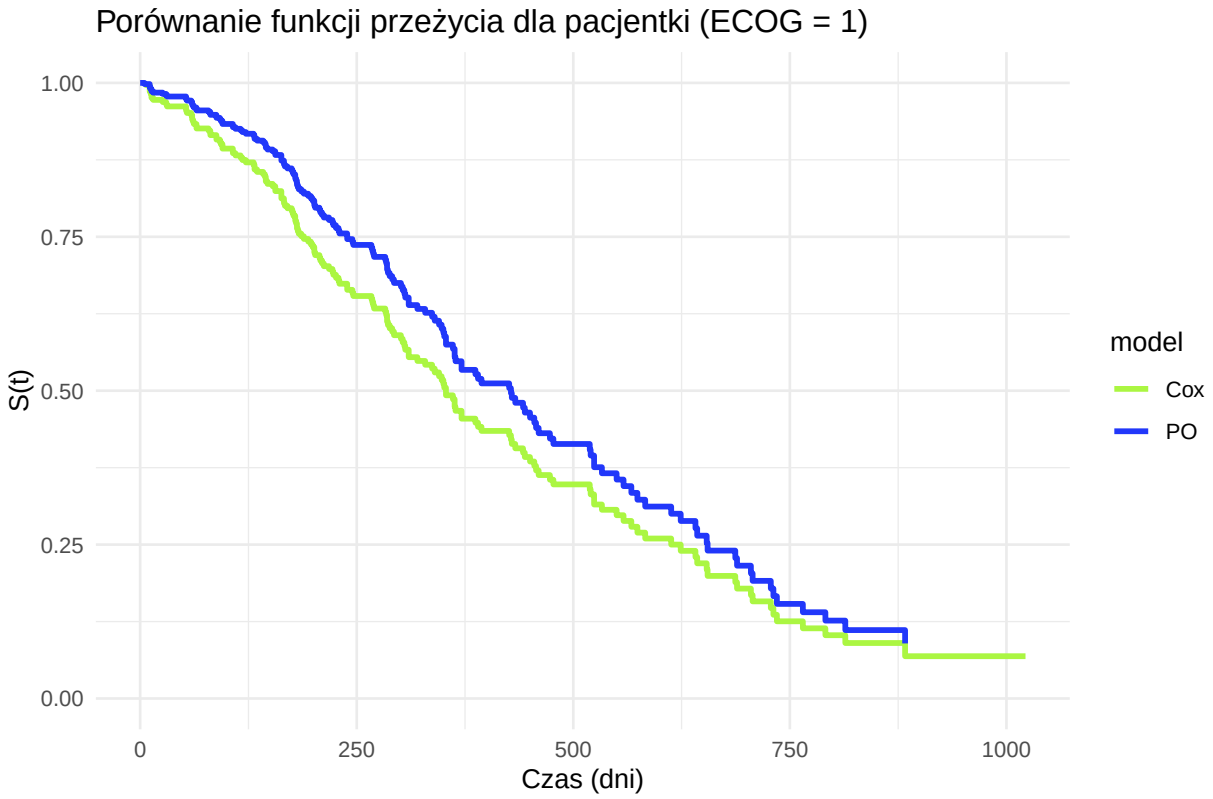

Rysunek 10: Porównanie estymowanych funkcji przeżycia – model Coxa vs model proporcjonalnych szans (ECOG = 1)

Jak można zauważyć na wykresie 10, estymowane funkcje przeżycia uzyskane w modelu proporcjonalnych szans oraz w modelu Coxa mają bardzo zbliżony przebieg w całym rozważanym horyzoncie czasu. Model proporcjonalnych szans systematycznie daje nieco wyższe wartości funkcji przeżycia niż model Coxa, co jest zgodne z wnioskami z poprzednich zadań.

4 Lista 12

W analizie zastosowano model przyspieszonego czasu awarii z bazową funkcją przeżycia odpowiadającą rozkładowi Weibulla. Jako zmienną zależną przyjęto time, natomiast jako charakterystyki uwzględniono *age, sex, ph.ecog* oraz *ph.karno*. Wszystkie wnioski oparte są na poziomie istotności $\alpha = 0.05$

W podpunkcie (a) zastosowano test Walda oraz test oparty na ilorazie wiarygodności (IW) w celu weryfikacji hipotezy, że zmienna *age* nie jest istotna statystycznie w przyjętym modelu.

```
model.aft.no.age <- survreg(Surv(time, status) ~
                      sex + ph.ecog + ph.karno_c,
                      data=dane, dist = "weibull")

# test Walda
summary.aft <- summary(model.aft)
wald.age.pval <- summary.aft$table["age_c", "p"]

# test IW
anova.age.aft <- anova(model.aft.no.age, model.aft)
anova.age.aft.pval <- anova.age.aft$`Pr(>Chi)`[2]
```

W teście Walda wartość poziomu krytycznego wynosi 0.2053, wobec czego na poziomie istotności 0.05 nie ma podstaw do odrzucenia hipotezy zerowej. Analogicznie, w teście opartym na ilorazie wiarygodności wartość p-value wynosi 0.2014, co również nie daje podstaw do odrzucenia hipotezy.

W podpunkcie (b) również zastosowano test Walda oraz IW, tym razem w celu weryfikacji hipotezy, że zmienna *sex* nie jest istotna statystycznie w przyjętym modelu.

```
model.aft.no.sex <- survreg(Surv(time, status) ~
                      age_c + ph.ecog + ph.karno_c,
                      data=dane, dist = "weibull")

# test Walda
wald.sex.pval <- summary.aft$table["sex2", "p"]

# test IW
anova.sex.aft <- anova(model.aft.no.sex, model.aft)
anova.sex.aft.pval <- anova.sex.aft$`Pr(>Chi)`[2]
```

Tutaj dla testu Walda wartość p-value wynosi około $9 \cdot 10^{-4}$, a test IW $6 \cdot 10^{-4}$, zatem w obu przypadkach odrzucamy naszą hipotezę, że zmienna *sex* nie jest istotna statystycznie dla modelu AFT.

W podpunkcie (c) zastosowano test IW do weryfikacji hipotezy, że rozkład czasu życia jest taki sam dla pacjentów o sprawności ECOG według lekarza na poziomach 0, 1, 2 oraz 3.

```
model.aft.no.ecog <- survreg(Surv(time, status) ~
                      age_c + sex + ph.karno_c,
                      data=dane, dist = "weibull")

# test IW
anova.ecog.aft <- anova(model.aft.no.ecog, model.aft)
anova.ecog.aft.pval <- anova.ecog.aft$`Pr(>Chi)`[2]
```

W tym przypadku wartość poziomu krytycznego wynosi około 0.0021, w związku z czym, na poziomie

istotności 0.05, odrzucamy hipotezę zerową, że rozkład czasu życia jest taki sam dla pacjentów o sprawności ECOG według lekarza na poziomach 0, 1, 2 oraz 3.

4.1 Zadanie 2

Zastosowano model proporcjonalnych hazardów Coxa ze zmienną zależną *time*, natomiast jako charakterystyki uwzględniono *age, sex, ph.ecog* oraz *ph.karno*. Wszystkie wnioski oparte są na poziomie istotności $\alpha = 0.05$

W podpunkcie (a) uwzględniono test Walda oraz IW i zweryfikowano hipotezę, że zmienna age nie jest istotna w przyjętym modelu.

```
model.cox.no.age <- coxph(Surv(time, status) ~ sex + ph.ecog + ph.karno_c,
                          data = dane)

# test Walda
summary.cox <- summary(model.cox)
wald.cox.age.pval <- summary.cox$coefficients["age_c", "Pr(>|z|)"]

# test IW
anova.age.cox <- anova(model.cox.no.age, model.cox)
anova.age.cox.pval <- anova.age.cox$`Pr(>|Chi|)`[2]
```

W teście Walda wartość poziomu krytycznego wynosi 0.1839, wobec czego na poziomie istotności 0.05 nie ma podstaw do odrzucenia hipotezy zerowej. Analogicznie, w teście opartym na ilorazie wiarygodności wartość p-value wynosi 0.1804, co również nie daje podstaw do odrzucenia hipotezy.

Dla podpunktu (b) skorzystano również z testu Walda i testu IW do weryfikacji hipotezy, że zmienna *sex* nie jest istotna w przyjętym modelu.

```
model.cox.no.sex <- coxph(Surv(time, status) ~ age_c + ph.ecog + ph.karno_c,
                          data = dane)

# test Walda
wald.cox.sex.pval <- summary.cox$coefficients["sex2", "Pr(>|z|)"]

# test IW
anova.sex.cox <- anova(model.cox.no.sex, model.cox)
anova.sex.cox.pval <- anova.sex.cox$`Pr(>|Chi|)`[2]
```

Dla testu Walda p-value wyniosło około $8.6 \cdot 10^{-4}$, więc odrzucamy hipotezę, że zmienna sex nie jest istotna w modelu. Dla testu IW p-value wyniosło około $6.3 \cdot 10^{-4}$, więc również odrzucamy hipotezę, że zmienna sex nie jest istotna w modelu.

Dla podpunktu (c) skorzystano z testu ilorazu wiarogodności weryfikując hipotezę, że rozkład czasu życia jest taki sam dla pacjentów o sprawności ECOG według lekarza na poziomach 0, 1, 2 oraz 3.

```
model.cox.no.ecog <- coxph(Surv(time, status) ~ age_c + sex + ph.karno_c,
                          data = dane)

# test IW
anova.ecog.cox <- anova(model.cox.no.ecog, model.cox)
anova.ecog.cox.pval <- anova.ecog.cox$`Pr(>|Chi|)`[2]
```

Wartość poziomu krytycznego wychodzi około 0.0036, zatem odrzucamy naszą hipotezę na poziomie istotności $\alpha = 0.05$.

4.2 Zadanie 3

Przyjęto model AFT z bazową funkcją przeżycia odpowiadającą rozkładowi Weibulla. Jako zmienną zależną przyjęto time, natomiast jako charakterystyki uwzględniono *age, sex, ph.ecog* oraz *ph.karno*.

W podpunkcie (a) w celu wyboru zmiennych do modelu przyspieszonego czasu awarii zastosowano metodę eliminacji wstecznej opartą na teście ilorazu wiarygodności. Punktem wyjścia był pełny model AFT, z którego w kolejnych krokach usuwano zmienną o największej wartości p-value, aż do momentu, w którym wszystkie zmienne pozostałe w modelu były istotne statystycznie na poziomie 0.05.

```
drop.test.aft1 <- drop1(model.aft, test = "Chisq")
```

Tabela 5: Wartości p-value w teście ilorazu wiarygodności dla metody eliminacji (model AFT)

Zmienna	p.value
age_c	0.2014
sex	0.0006
ph.ecog	0.0021
ph.karno_c	0.1332

Możemy zauważyć, że największą wartość poziomu krytycznego ma zmienna *age*, także eliminujemy ją tworząc kolejny model.

```
model.aft2 <- survreg(Surv(time, status) ~
                      sex + ph.ecog + ph.karno_c,
                      data=dane, dist = "weibull")

drop.test.aft2 <- drop1(model.aft2, test = "Chisq")
```

Tabela 6: Wartości p-value w teście ilorazu wiarygodności dla metody eliminacji (model AFT) po pierwszej eliminacji

Zmienna	p.value
sex	0.0007
ph.ecog	0.0020
ph.karno_c	0.1756

Możemy przyjrzeć się, że największe p-value ma zmienna *ph.karno*, także teraz ją eliminujemy i tworzymy kolejny model.

```
model.aft3 <- survreg(Surv(time, status) ~
                      sex + ph.ecog,
                      data=dane, dist = "weibull")

drop.test.aft3 <- drop1(model.aft3, test = "Chisq")
```

Tabela 7: Wartości p-value w teście ilorazu wiarygodności dla metody eliminacji (model AFT) po drugiej eliminacji

Zmienna	p.value
sex	0.0011
ph.ecog	0.0004

W modelu zostały dwie zmienne, które obie mają wartość p-value niższą niż poziom istotności, zatem model ma dwie charakterystyki: *sex* oraz *ph.ecog*

Dla naszego ostatecznego modelu współczynnik *sex* ma współczynnik równy -0.39, co wskazuje na dłuższy czas przeżycia kobiet w porównaniu z mężczyznami. Współczynniki *ph.ecog* dla wskaźników 1,2,3 wynoszą odpowiednio: 0.2964, 0.6789 oraz 1.42. Rosnące wartości współczynników przy kolejnych poziomach zmiennej *ph.ecog* wskazują, że wraz ze wzrostem poziomu ECOG oczekiwany czas przeżycia ulega wydłużeniu.

W podpunkcie (b) zastosowano kryterium informacyjne Akaike'a (AIC) i za pomocą jego dokonano wyboru najlepszego modelu przyspieszonego czasu awarii.

```r
aic.aft <- step(model.aft, direction="backward")
```

```
## Start:  AIC=2266.6
## Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c
##
##              Df    AIC
## - age_c       1 2266.2
## <none>          2266.6
## - ph.karno_c  1 2266.8
## - ph.ecog     3 2275.2
## - sex         1 2276.4
##
## Step:  AIC=2266.23
## Surv(time, status) ~ sex + ph.ecog + ph.karno_c
##
##              Df    AIC
## - ph.karno_c  1 2266.1
## <none>          2266.2
## - ph.ecog     3 2275.0
## - sex         1 2275.8
##
## Step:  AIC=2266.07
## Surv(time, status) ~ sex + ph.ecog
##
##           Df    AIC
## <none>       2266.1
## - sex      1 2274.7
## - ph.ecog  3 2278.4
```

Procedurę rozpoczęto od pełnego modelu AFT obejmującego zmienne *age*, *sex*, *ph.ecog* oraz *ph.karno*. Następnie, w kolejnych krokach, eliminowano pojedyncze zmienne w celu minimalizacji wartości kryterium informacyjnego Akaike'a. W pierwszym etapie usunięto zmienną *age*, natomiast w kolejnym usuniętą

ph.karno. Ostatecznie uzyskano model identyczny z modelem otrzymanym w podpunkcie (a), o tej samej interpretacji.

W podpunkcie (c) zastosowano bayesowskie kryterium informacyjne (BIC) i za pomocą jego dokonano wyboru najlepszego modelu przyspieszonego czasu awarii. Chociaż funkcja *step* standardowo wykorzystuje kryterium AIC, to przy ustawieniu parametru $k = \ln(S)$, gdzie S - ilość danych kompletnych, procedura ta odpowiada wyborowi modelu według kryterium BIC.

```
S <- sum(dane$status) # ilość danych kompletnych
bic.aft <- step(model.aft, direction="backward", k=log(S))
```

```
## Start:  AIC=2298.31
## Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c
##
##              Df    AIC
## - age_c       1 2294.0
## - ph.karno_c  1 2294.6
## - ph.ecog     3 2295.1
## <none>          2298.3
## - sex         1 2304.1
##
## Step:  AIC=2293.98
## Surv(time, status) ~ sex + ph.ecog + ph.karno_c
##
##              Df    AIC
## - ph.karno_c  1 2289.8
## - ph.ecog     3 2290.8
## <none>          2294.0
## - sex         1 2299.6
##
## Step:  AIC=2289.85
## Surv(time, status) ~ sex + ph.ecog
##
##           Df    AIC
## <none>       2289.8
## - ph.ecog  3 2290.3
## - sex      1 2294.6
```

W tym przypadku, podobnie jak w podpunkcie (b), wyeliminowana najpierw została charakterystyka *age*, a później *ph.karno*, pozostawiając charakterystyki *ph.ecog, sex*. Interpretacja współczynników zatem będzie również taka sama jak w podpunkcie (a).

4.3 Zadanie 4

Przyjęto model proporcjonalnych hazardów Coxa. Jako zmienną zależną przyjęto time, natomiast jako charakterystyki uwzględniono *age, sex, ph.ecog* oraz *ph.karno*.

Dla podpunktu (a) wykonano metodę eliminacji w oparciu o test IW.

```
drop.test.cox1 <- drop1(model.cox, test = "Chisq")
```

Tabela 8: Wartości p-value w teście ilorazu wiarygodności dla metody eliminacji (model PH Cox)

Zmienna	p.value
age_c	0.1804
sex	0.0006
ph.ecog	0.0036
ph.karno_c	0.1886

Możemy zauważyć, że największą wartość poziomu krytycznego ma zmienna *ph.karno*, także eliminujemy ją tworząc kolejny model.

```
model.cox2 <- coxph(Surv(time, status) ~ age + sex + ph.ecog, data = dane)

drop.test.cox2 <- drop1(model.cox2, test = "Chisq")
```

Tabela 9: Wartości p-value w teście ilorazu wiarygodności dla metody eliminacji (model PH Cox) po pierwszej eliminacji

Zmienna	p.value
age	0.2343
sex	0.0010
ph.ecog	0.0010

Możemy przyjrzeć się, że największe p-value ma zmienna *age*, także teraz ją eliminujemy i tworzymy kolejny model.

```
model.cox3 <- coxph(Surv(time, status) ~ sex + ph.ecog, data = dane)

drop.test.cox3 <- drop1(model.cox3, test = "Chisq")
```

Tabela 10: Wartości p-value w teście ilorazu wiarygodności dla metody eliminacji (model PH Cox) po drugiej eliminacji

Zmienna	p.value
sex	1e-03
ph.ecog	4e-04

```
##       sex2   ph.ecog1   ph.ecog2   ph.ecog3
## -0.5387885  0.4186114  0.9314840  2.0689288
```

W modelu zostały dwie zmienne, które obie mają wartość p-value niższą niż poziom istotności, zatem model ma dwie charakterystyki: *sex* oraz *ph.ecog*.

W modelu końcowym proporcjonalnych hazardów Coxa oszacowany współczynnik przy zmiennej *sex* wynosi -0.5388, co wskazuje, że kobiety charakteryzują się mniejszym ryzykiem zgonu w porównaniu z mężczyznami. Współczynniki przy zmiennej *ph.ecog* dla poziomów 1, 2 oraz 3 wynoszą odpowiednio: 0.4186, 0.9315 oraz -0.6789. Rosnące wartości tych współczynników wskazują, że wraz ze wzrostem poziomu

sprawności ECOG według lekarza zwiększa się ryzyko zgonu w porównaniu z niższymi poziomami tej zmiennej.

W podpunkcie (b) zastosowano kryterium AIC i za pomocą jego dokonano wyboru najlepszego modelu proporcjonalnych hazardów Coxa.

```
aic.cox <- step(model.cox, direction="backward")
```

```
## Start:  AIC=1458.54
## Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c
##
##              Df    AIC
## - ph.karno_c  1 1458.3
## - age_c       1 1458.3
## <none>          1458.5
## - ph.ecog     3 1466.0
## - sex         1 1468.2
##
## Step:  AIC=1458.27
## Surv(time, status) ~ age_c + sex + ph.ecog
##
##           Df    AIC
## - age_c    1 1457.7
## <none>       1458.3
## - sex      1 1467.0
## - ph.ecog  3 1468.5
##
## Step:  AIC=1457.68
## Surv(time, status) ~ sex + ph.ecog
##
##           Df    AIC
## <none>       1457.7
## - sex      1 1466.5
## - ph.ecog  3 1470.1
```

Procedurę rozpoczęto od pełnego modelu proporcjonalnych hazardów Coxa obejmującego zmienne *age*, *sex*, *ph.ecog* oraz *ph.karno*. Następnie, w kolejnych krokach, eliminowano pojedyncze zmienne w celu minimalizacji wartości kryterium informacyjnego Akaike'a. W pierwszym etapie usunięto zmienną *age*, natomiast w kolejnym — *ph.karno*. Ostatecznie uzyskano model identyczny z modelem otrzymanym w podpunkcie (a), o tej samej interpretacji.

W podpunkcie (c) zastosowano BIC i za pomocą jego dokonano wyboru najlepszego modelu proporcjonalnych hazardów Coxa.

```
bic.cox <- step(model.cox, direction="backward", k=log(S))
```

```
## Start:  AIC=1482.32
## Surv(time, status) ~ age_c + sex + ph.ecog + ph.karno_c
##
##              Df    AIC
## - ph.ecog     3 1477.9
## - ph.karno_c  1 1478.1
## - age_c       1 1478.2
```

```
## <none>          1482.3
## - sex         1 1488.0
##
## Step:  AIC=1477.94
## Surv(time, status) ~ age_c + sex + ph.karno_c
##
##              Df    AIC
## - age_c       1 1473.9
## - ph.karno_c  1 1476.5
## <none>          1477.9
## - sex         1 1480.9
##
## Step:  AIC=1473.86
## Surv(time, status) ~ sex + ph.karno_c
##
##              Df    AIC
## <none>          1473.9
## - ph.karno_c  1 1474.1
## - sex         1 1477.1
```

W tym przypadku, analogicznie jak w podpunkcie (b), w pierwszym kroku wyeliminowano zmienną *age*, a następnie *ph.karno*, pozostawiając w modelu charakterystyki *sex* oraz *ph.ecog*. Interpretacja oszacowanych współczynników w modelu proporcjonalnych hazardów Coxa jest zatem taka sama jak w podpunkcie (a).